基于正常模板与多模态大模型的 PCB 缺陷检测结果复核方法

Reference-Guided Multimodal Verification for PCB Defect Detection

匿名作者

***Abstract*—针对 PCB 表面缺陷检测器在细粒度线路变化、正常纹理扰动和相似缺陷类别下出现的误报、漏检与错分类问题，本文提出一种基于正常模板与多模态大模型的检测结果复核方法。方法联合基础检测器的语义候选与正常模板的差异候选构建统一候选集合，使系统既能复核已有检测结果，也能验证检测器未提出的潜在漏检区域；在此基础上由学习式复检门控制大模型的调用预算，由外部证据驱动的接受门约束修改动作是否执行。在 DeepPCB 上按模板组隔离的五折交叉验证表明，基础检测器留下 1644 个可纠错错误，其中漏检占 57.6%。不加门控时大模型复检的有害修正率达到 0.9326，最终 F1 由 0.9118 降至 0.8660；引入双门控后正确检测保留率为 0.9998，最终 F1 与基础检测器无统计差异。复检门在 5% 调用预算下定位 46.5% 的可纠错错误，随机策略仅为 3.2%。证据消融显示正常模板是唯一稳定的增益来源，而外观差异图与拓扑差异图作为大模型视觉输入未带来增益。接受上界分析进一步表明，即使完美采纳大模型的全部提议，最终 F1 也仅比基础检测器高 0.0025，说明当前多模态大模型在工业细粒度缺陷验证上的判断质量是系统的主要瓶颈。**

***Index Terms*—PCB 缺陷检测，检测结果复核，正常模板参照，多模态大模型，选择性预测，风险门控**

I. 绪论

印制电路板（Printed Circuit Board，PCB）是电子产品中承载器件、连接电气网络并保证信号传输的基础部件。线路开路、短路、鼠咬、毛刺、针孔和多余铜等表面缺陷可能改变局部导通状态，也可能在后续装配与服役阶段演化为间歇性故障。随着线路密度提高和制造节拍加快，依靠人工逐板检查难以同时满足一致性、速度与成本要求。自动光学检测（Automated Optical Inspection，AOI）因而成为 PCB 制造质量控制中的关键环节，其典型流程是先快速定位疑似区域，再由规则、模型或操作员复判报警是否成立 [1], [2]。复判并非检测流程之外的附属步骤。误报过多会增加停线和人工确认成本，漏检则可能让结构性缺陷进入后续工序，所以复判系统必须同时关心纠错收益、正确结果保护与处理开销。

近年来，基于卷积神经网络和视觉 Transformer 的目标检测器显著提高了 PCB 缺陷定位的自动化程度 [3], [2]。这类方法通常把待检图像作为主要输入，通过多尺度特征学习识别局部纹理异常。单图检测范式仍存在结构性局限。PCB 缺陷往往只占几十个像素，细小目标在下采样过程中容易丢失；正常线路具有重复、密集和高度相似的局部纹理，灰尘、反光与轻微成像偏差又可能形成类似缺陷的响应。更重要的是，开路与短路等类别的判别依据不是普通物体的外观语义，而是线路是否保持应有的连通、隔离和分支关系。一个局部亮斑究竟是多余铜、正常焊盘还是光照扰动，仅从当前图像很难稳定判断。继续叠加检测头、注意力模块或损失项可以改善特征表达，却没有改变系统缺少同位置正常状态这一事实。

正常模板为上述问题提供了直接的反事实参照。单图检测器回答“该区域是否像缺陷”，模板比较进一步回答“该位置相对正常设计发生了什么变化”。对开路而言，参照图揭示本应连续的铜线；对短路而言，参照图显示本应隔离的线路；对鼠咬、毛刺、针孔和多余铜而言，参照图分别给出完整边缘、正常轮廓、孔结构及铜区范围。配对参考由此把不确定的外观识别转化为受正常结构约束的变化判断。参考式 PCB 检测和工业变化检测已经说明模板信息具有应用价值 [3], [4]，但模板差分本身也会受配准误差、光度变化和阈值噪声影响。差异区域适合提出待验证假设，却不应直接等同于真实缺陷。

多模态大模型能够联合理解局部图像、正常参照和封闭缺陷定义，为候选级复判提供新的技术路径 [5], [6], [7]。相较于固定阈值规则，其价值在于组合多种视觉线索，并在预先限定的类别空间内给出结构化判断。通用多模态大模型也带来明确风险：模型对极小异常可能不敏感，可能依赖文字先验而非视觉证据，可能幻觉不存在的结构，其自报置信度也不能直接作为工业决策保证。若把整幅 PCB 图像交给模型自由定位，不仅调用成本高，还会引入不可控的新框；若把基础检测器的类别和置信度直接写入提示，验证结果又可能受既有答案锚定。工业场景需要的不是一个无条件覆盖检测器的“大模型裁判”，而是局部、选择性、可审计且受安全规则约束的验证器。

基于这一认识，本文研究挂接在基础检测器之后的 PCB 缺陷结果复核问题。系统以检测器候选和模板差异候选构成统一的候选空间，只让多模态大模型判断已有候选，不允许其自由生成任意位置。学习式复检门选择值得调用模型的高风险候选，接受门再判断提议修改是否具备足够外部证据。两个门分别回答“要不要看”和“敢不敢改”，从机制上分离调用效率与修改安全性。最终证据卡采用实验确定的 A2 设计，仅包含当前紧裁剪、正常模板紧裁剪和更大上下文三个面板。外观差异图与拓扑差异图不作为大模型视觉输入，拓扑向量用于门控决策。该设计承认多模态大模型能力有限，并把能力边界纳入系统构造和实验评价。

本文的贡献严格归纳为以下三点。

1) **面向漏检恢复的双来源候选机制。**联合检测器语义候选与正常模板差异候选，在统一候选空间中处理误报、错分类与检测器未提出候选的漏检。实验支撑：差异候选的漏检恢复候选率为 0.625（IoU 0.3），候选上界 F1 为 0.9555，相对基线 0.9118 留有 +0.044 空间，证明候选覆盖不是瓶颈。五折错误分解显示漏

检占可纠错空间 57.6%，是最大错误类型，该机制针对的正是主要矛盾。

2) **风险受控的分级复检机制。**学习式复检门控制调用预算，外部证据驱动的接受门约束修改动作。复检门在 5% 调用预算下定位 46.5% 的可纠错错误，随机策略仅为 3.2%，效率为 14.8 倍。接受门保证任何调用预算下最终 F1 不低于基线；无接受门时，F1 随预算从 0.9088 跌至 0.8660。正确检测保留率为 0.9998，734 个正确检测仅误删 2 个。无门控时有害修正率为 0.9326，双门控将其阻断。这是全文最强的实证结论。

3) **多模态大模型作为工业细粒度缺陷验证器的能力边界实证。**证据消融证明正常模板是唯一稳定的增益来源，A2 相对 A0 提升 0.1178，置信区间不跨 0，而外观差异图、拓扑差异图、数值拓扑摘要的全部变体均低于仅用模板的配置。实验已排除渲染自动拉伸与配准残差两个混淆解释。Oracle 分析将瓶颈精确定位：候选上界为 0.9555，仍留有空间，但接受上界仅为 0.9143，比基线高 0.0025，说明大模型提出的修改中缺乏足够多的正确项。附加对照进一步刻画边界：去锚定未见收益、配准不可靠提示为负资产、自由文本输出的 JSON 可解析率为 0。

本文其余内容组织如下。第 II 节梳理 PCB 缺陷检测、正常模板比较、工业异常多模态理解及选择性决策研究。第 III 节形式化定义双来源候选、六种复核动作及整体数据流。第 IV 节介绍模板处理、差异候选生成、候选融合和三面板证据卡。第 V 节说明复检门、多模态大模型判断、动作映射、接受门和最终融合。第 VI 节给出实验设置、证据消融、端到端纠错、预算曲线与鲁棒性分析。第 VII 节总结研究结论、局限和后续方向。

II. 相关工作

A. PCB 缺陷检测与公开数据集

公开数据集推动了 PCB 缺陷检测从手工规则向数据驱动方法转变。DeepPCB 包含 1500 对已配准的正常模板与待检图像，并标注六类常见裸板缺陷，其原始检测器直接以图像对为输入 [3]。Huang 和 Wei 发布的数据集包含 10 个模板和 1386 张合成缺陷图像，同时提供检测、分类与配准任务所需信息 [8]。这两类数据保留了正常参考，适合研究配对比较，但图像规模和缺陷生成方式与真实产线仍有差距。

近年的数据集更强调真实制造条件。DsPCBSD+ 收集产线 AOI 图像并按缺陷成因、位置与形态细分类型 [9]；PCB-IND 则保留工业成像中的非均匀照明、长尾分布和跨尺度缺陷 [10]。工业异常检测领域的 VisA 覆盖 12 类对象并提供图像级与像素级标注，其中包含 PCB 类别 [11]。这些数据扩大了场景多样性，却不都提供与每张待检图严格对应的正常模板。本文因此以 DeepPCB 的配对结构完成主要实验，并将跨模板、跨产线验证视为后续工作，而不把无配对参考的数据包装为完整的模板复核实验。

B. 参考模板对比与变化检测

参考式 PCB 检测并非新的问题设定。DeepPCB 的方法联合编码正常模板和待检图，通过组金字塔池化预测缺陷 [3]。Auto-VRS 在 AOI 之后执行快速电路比较，再用深度网络判断候选是真缺陷还是伪缺陷，已经形成后置验证流程 [1]。CSS-Net 使用标准板与候选图像构成孪生输入，并以代价敏感阈值减少真实缺陷被判为伪缺陷的风险 [12]。两者说明，检测后复核和参考图二次分类本身不能构成本文的独立创新。

ChangeChip 将 golden PCB 与待检板配准后进行无监督变化检测，以显著变化区域提示缺陷 [4]。RefDiffNet 在检测器主干之前加入轻量参考比较模块，将结构变化编码为增强后的检测输入，并在 DeepPCB 与 HRIPCB 上测试其可插拔性 [13]。这些工作分别代表独立变化检测和检测前参考增强。本文关注的对象不同：基础检测器先产生候选，差异候选补充其可能漏掉的区域，大模型只复核候选级假设，系统再通过接受门决定是否修改基础输出。本文实验也表明，将外观差异图与拓扑图直接作为大模型视觉证据没有稳定增益，因此最终系统移除了该输入，而不是把显式差异证据宣称为有效贡献。

C. 工业异常检测中的多模态大模型

AnomalyGPT 通过异常数据构造、视觉解码器和提示学习增强大视觉语言模型对局部工业异常的感知 [14]。VMAD 将视觉异常知识和细粒度局部特征注入多模态大模型，用于零样本检测、定位与解释 [15]。EMIT 进一步采用面向困难样本的 GRPO 训练，以领域数据和热图引导提升工业异常任务表现 [16]。这类方法主要改造模型本体，说明通用多模态大模型对微小工业异常的视觉能力仍需专门适配。

基准研究给出了更直接的能力边界。MMAD 将工业异常检查拆分为识别、分类、定位、描述和分析等子任务，发现现有多模态大模型距离工业要求仍有明显差距 [5]。Anomaly-OV 通过异常视觉 token 和特征匹配强化细粒度异常感知 [6]。UniPCB 面向开放式 PCB 质量检查构建统一视觉语言基准，并报告通用模型在领域任务上的不足 [17]。DifferAD-R1 采用正常图与待检图的双图差异引导，将工业异常定位表述为差异 grounding 问题 [18]。因此，“参考图加多模态大模型”也不是本文的创新边界。本文把大模型放在已有检测器之后，并用分级复检门控制调用，用接受门和安全规则约束修改，研究重点是复核系统的成本与风险，而非训练新的异常感知大模型。

D. 选择性预测、校准与验证器可靠性

复核系统需要同时回答“哪些候选值得调用昂贵模型”和“模型给出的修改能否执行”。SelectiveNet 将拒识机制与预测器联合训练，以风险和覆盖率描述选择性预测 [19]。温度缩放使用单一参数校准神经网络置信度，为检测器工作点和门控特征提供了简单基线 [20]。Learning to Defer 学习把样本交给下游专家的条件，并把系统性能而非单一模型精度作为优化对象 [21]。Conformal Risk Control 则把共形方法扩展到单调损失的期望风险控制 [22]。这些研究共同表明，覆盖率、风险和校准应当分开报告，模型的高置信度不能直接等同于动作安全。

把多模态大模型用作验证器还会引入新的偏差。研究发现 MLLM 可能过度认可给定行为或既有答案，即同意偏差；先形成独立先验再验证候选可以缓解该问题 [7]。自我修正综述指出，在缺少可靠外部反馈时，仅依赖模型自评并不能稳定改正错误 [23]。视觉语言模型的选择性预测研究也显示，外部视觉与几何信号比模型自报置信度更有判别力 [24]。本文据此不直接执行大模型输出，而是让接受门结合候选来源、配准质量、检测置信度和动作类型做系统侧决策，并以硬安全规则保护已有正确检测。

E. 本文定位与差异化矩阵

表 I 按最终实验结论重新界定本文位置。符号“有”只表示对应机制在该工作中明确出现，不把检测前增强、独立异常定位或开放式问答等同于检测器后置修正。本文保留配对参考、差异候选和配准可靠性信号，但已移除被实验证明无效的显式差异视觉输入。

本文的差异化不依赖“首次使用模板、差异图或大模型复核”的主张，而落在三个可检验的系统机制上：检测候选与差异候选的双来源互补，面向有限调用预算的分级复检门，以及约束大模型修改的接受门与安全规则。实验结果同时用于刻画边界：正常模板是稳定的视觉增益来源，显式外观与拓扑证据未产生稳定增益，去锚定输入也未显示优势。这样的定位把正面结果与负面结果纳入同一风险受控复核框架。

III. 问题定义与总体框架

A. 任务定义

本文研究 PCB 基础检测结果的候选级复核。给定待检图像 I、与其对应的正常模板 R、基础检测器 D、封闭缺陷知识集合 K 以及多模态验证器 V，目标是在有限验证预算下修正基础检测器的误报、漏检与错分类，同时尽量保持已经正确的检测结果。知识集合 K 只包含系统允许识别的缺陷类别、类别定义和结构化输出约束。验证器 V 读取候选对应的局部证据与 K，输出独立的缺陷存在性和类别判断。它不是全图检测器，也不直接决定最终检测集合。

基础检测器在待检图像上产生检测候选集合

$$C_{\mathrm{det}} = D(I) = \{(b_i, c_i, p_i)\}_{i=1}^{N_d}, \tag{1}$$

其中 b_i 为边界框，c_i 为封闭类别空间中的预测类别，p_i 为校准后的检测置信度，N_d 为检测候选数量。检测候选提供较强的语义定位能力，但其覆盖范围受基础检测器召回率限制。若某个真实缺陷没有对应检测框，仅在 C_{det} 内执行删除和改类无法恢复该漏检。

为扩展可复核空间，系统将 I 与经过几何配准和光度归一的模板进行比较，从外观变化和结构变化中生成差异候选

$$C_{\mathrm{diff}} = \{(\tilde{b}_j, s_j^{\mathrm{app}}, s_j^{\mathrm{topo}})\}_{j=1}^{N_a}, \tag{2}$$

其中 $\tilde{b}_j$ 是差异模块提出的边界框，s_j^{app} 与 s_j^{topo} 分别表示候选区域的外观差异和拓扑差异摘要，N_a 为差异候选数量。C_{diff} 的作用是提出“该处可能相对正常模板发生变化”的假设，不预先断言该变化一定属于缺陷。配准残差、光照变化和材料纹理都可能形成差异噪声，因此 DIFF 候选需要经过后续验证与接受约束。

融合算子根据框重叠和中心关系合并两个来源，形成统一候选集合

$$C = \mathrm{Fuse}(C_{\mathrm{det}} \cup C_{\mathrm{diff}}). \tag{3}$$

每个候选 $x_i \in C$ 带有来源标记

$$o_i \in \{\mathrm{DET}, \mathrm{DIFF}, \mathrm{BOTH}\}. \tag{4}$$

DET 表示候选仅由基础检测器提出，DIFF 表示候选仅由模板差异模块提出，BOTH 表示两个来源在同一局部区域共同支持该候选。来源标记既记录候选的形成路径，也限定后续动作的合法集合。对 BOTH 候选，视觉复核可以使用融合区域构造上下文，但保留、删除和改类仍作用于检测器原框，避免融合框改变原始定位语义。

系统为每个统一候选选择动作

$$a_i \in \mathcal{A} = \{\texttt{keep}, \texttt{remove}, \texttt{relabel}, \texttt{add}, \texttt{reject}, \texttt{defer}\}. \tag{5}$$

六种动作定义如下。

- `keep`：保留检测器原框、原类别与原置信度，适用于 DET 或 BOTH 候选。
- `remove`：删除被判定为误报的检测器原框，适用于 DET 或 BOTH 候选。
- `relabel`：保留检测器原框和校准置信度，仅把类别改为封闭类别集合中的另一类别，适用于 DET 或 BOTH 候选。
- `add`：接受差异模块已经提出的边界框，并把接受门输出作为新增框分数，适用于没有检测框覆盖的 DIFF 候选。
- `reject`：拒绝差异噪声候选，不向最终结果加入边界框，主要适用于 DIFF 候选。
- `defer`：当证据不足、配准不可靠或模型判断不确定时不执行自动修改，把候选保留为待人工处理或沿用默认结果。

动作空间受到两条硬约束。其一，验证器不得在统一候选集合之外自由生成新框。验证器只判断系统已经构造的候选假设，候选几何位置由基础检测器或模板差异模块确定。其二，`add` 只能接受 C_{diff} 中已有的差异候选，DET 和 BOTH 候选均不得通过该动作重复增加框。这一约束把多模态大模型的角色限定为验证者，将开放式视觉生成转换为封闭候选上的受控决策。

在预算约束 B 下，系统只对复检门选中的候选调用 V。设 $g_r(x_i)$ 为候选需要复核的风险分数，$g_a(x_i, a_i)$ 为提议动作的接受概率，则自动修改需同时满足复检选择、配准质量阈值、接受阈值和动作安全规则：

$$\mathrm{Apply}(a_i) = 1 \Longleftrightarrow x_i \in \mathrm{TopB}(g_r), \quad q_{\mathrm{reg}} \geq \tau_{\mathrm{reg}}, \quad g_a(x_i, a_i) \geq \tau_a, \quad \text{S} \tag{6}$$

复检门控制昂贵验证器的调用对象，接受门控制验证器建议能否改变结果。两者对应不同的学习目标，不能用单一置信阈值替代。

B. 总体数据流

图 1 给出系统总体框架。待检图像与正常模板先进入配准和光度归一模块，得到对齐模板及配准质量 q_{reg}。对齐图像对分别产生外观差异和结构差异，两类差异共同服务于差异候选生成。与此同时，基础检测器直接处理待检图像并输出校准后的检测候选。两个候选集合经过融合后附加 DET、DIFF 或 BOTH 来源标记，进入统一的候选级处理流程。

统一候选先经过复检门。低风险 DET 或 BOTH 候选沿用检测器结果，低风险 DIFF 候选默认拒绝，从而避免把大模型调用浪费在明确样本上。高风险且位于调用预算内的候选才构造 A2 证据卡。该证据卡严格包含三个面板：当前候选紧裁剪、正常模板同位置紧裁剪和带候选框的更大上下文。外观差异图与拓扑差异图不进入证据卡。外观与结构分析仍用于提出 C_{diff}，八维拓扑向量则作为复检门和接受门的候选特征。这一信息分工来自证据消融结论，避免把无稳定收益的差异渲染继续作为模型视觉输入。

TABLE I
相关方法与本文最终系统的差异化定位

方法	配对正常参考	显式差异证据	大模型验证	后置修正检测器	差异候选恢复漏检	配准质量门	分级复检门控	接受门与安全规则
DeepPCB[3]	有	无	无	无	无	无	无	无
Auto-VRS[1]	有	有	无	有	无	无	无	无
CSS-Net[12]	有	无	无	有	无	无	无	无
ChangeChip[4]	有	有	无	无	无	部分	无	无
RefDiffNet[13]	有	有	无	检测前增强	无	无	无	无
UniPCB[17]	部分任务	可选	检测与问答	无	无	无	无	无
DifferAD-R1[18]	有	有	定位	无	无	无	无	无
本文	有	**实验证明无效，已移除**	有	有	有	有	有	有

验证器结合三面板证据卡与封闭知识 K 输出缺陷是否存在、预测类别、参考可靠性和固定原因码。系统侧随后把独立判断与候选来源、检测器结果进行比较，将其映射为六种动作之一。修改类动作继续经过接受门、配准阈值和安全规则，未获接受的提议回退到默认处理。全部候选动作执行后，类别感知非极大值抑制消解重复或冲突框，输出最终检测集合和完整审计记录。该数据流保留基础检测器的高吞吐定位能力，同时将正常模板和多模态判断集中用于高风险候选。

C. 模块划分与职责

表 II 列出 M0 至 M11 的输入、输出与职责。模块边界按照可复现的数据流划分，差异候选、证据卡和门控特征各自承担单一功能。

十二个模块构成从快速检测到保守修正的闭环。M0 至 M5 决定系统“能够复核什么”，其中双来源设计把漏检恢复纳入候选空间；M6 决定“哪些候选值得看”；M7 与 M8 形成受限的多模态验证过程；M9 和 M10 决定“模型建议是否允许改变结果”；M11 保证输出格式与基础检测器兼容并保留审计轨迹。框架不要求多模态大模型独立完成 PCB 检测，而是利用其候选级比较能力，并通过外部证据与规则约束其不稳定性。

IV. 双来源候选与外观结构差异证据

本章给出检测候选之外的第二条候选生成路径。其基本出发点是，基础检测器只能复核已经提出的目标，不能处理根本没有检测框的漏检；正常模板则提供同一位置在无缺陷状态下的反事实参照，可用于发现检测器未覆盖的变化区域。本文先将正常模板配准到待检图坐标系，分别计算外观差异和拓扑差异，再把差异区域转换为连通域候选，并与检测器候选融合。外观图和拓扑图在候选生成阶段仍有作用，但阶段 B2 的专门诊断表明，将二者直接呈现给多模态大模型会降低候选判断性能。因此，本章区分“用于提出候选的机器特征”和“用于大模型判断的视觉证据”，不假定同一种表示对两个环节都有效。

A. 模板配准与光度归一（*M1*）

设待检图为 I，与其模板编号对应的正常图为 R。虽然 DeepPCB 按成对文件提供二者，但文件配对不等于像素级对齐。若直接计算残差，轻微平移和旋转会在铜线边缘形成成片的双边响应，使正常结构被误认为缺陷。M1 因而采用粗到细的两级配准。粗级利用数据目录中的模板标识取得正确参考，并在灰度图像金字塔上估计全局运动；细级以增强相关系数（enhanced correlation coefficient, ECC）为目标优化轻量仿射变换：

$$\hat{T} = \arg\max_{T} \mathrm{ECC}\big(I, W(R;T)\big), \qquad R' = W(R;\hat{T}), \quad (7)$$

其中 $W(\cdot;T)$ 表示将模板变换到待检图坐标系。仿射模型能够表达数据中的小幅平移、旋转和尺度变化，又比无约束单应模型更不容易把局部缺陷吸收到几何变换中。金字塔上层先处理低频结构和较大位移，下层再修正铜线边缘的亚像素残差。

ECC 未收敛、相关性过低或变换参数越界时，系统回退到 ORB 特征匹配与 RANSAC 单应估计。该分支先在两图中提取二值描述子，以匹配点形成候选对应关系，再用 RANSAC 排除受缺陷和重复线路影响的外点。回退分支的目的不是用更高自由度持续追求较小残差，而是在 ECC 失效时恢复可用的全局对应。若两个分支均不可靠，系统保留基础检测结果，并禁止由模板差异触发自动新增、删除或改类，避免错误参考继续向后传播。

阶段 0 的数据实况核查直接验证了配准模块的必要性。固定种子抽取的 50 对 DeepPCB 样本中，ECC 相关系数中位数为 0.99，但估计平移的绝对值最大达到 8.62 px；采用 $|t_x| \le 1$ px、$|t_y| \le 1$ px 且 $|\theta| \le 0.1°$ 的近零变换标准时，仅有 21/50 对达标。该结果说明 DeepPCB 原图近似对齐却未预配准到像素级，M1 处理的是实际存在的小残余错位和少数较大错位，而不是形式上的空操作。较高的 ECC 中位数也说明参考图总体对应正确，不能据此省略边缘级精配准。（数字来源：阶段 0 数据实况核查。）

几何对齐后，本文使用中位数和中位绝对偏差（median absolute deviation, MAD）进行稳健光度归一：

$$\widetilde{I} = \frac{I - \mathrm{median}(I)}{\mathrm{MAD}(I) + \epsilon}, \qquad \widetilde{R} = \frac{R' - \mathrm{median}(R')}{\mathrm{MAD}(R') + \epsilon}. \quad (8)$$

中位数削弱整体亮度偏移，MAD 降低少量高亮反射和缺陷像素对尺度估计的影响。该步骤在一般扫描图像中可抑制曝光与反射差异，但在 DeepPCB 上不能夸大其收益。阶段 0 对 3001 张 JPEG 解码图的统计显示，灰度值为 0 或 255 的像素占 93.99%，数据是近二值图而非具有丰富连续光度的自然图像。光度归一的可改善空间有限，不过其余 6.01% 像素仍包含 JPEG 灰度和待检图特有的强度变化，因此保留该步骤作为低成本的稳健预处理，而不把后续增益归因于连续纹理建模。（数字来源：阶段 0 数据实况核查。）

M1 同时输出配准质量分 $q_{\mathrm{reg}} \in [0,1]$。本文不以单一 ECC 值替代可靠性，而将 ECC 相关系数、ORB/RANSAC 内点率、边缘双向 Chamfer 距离、剔除最高残差区域后的

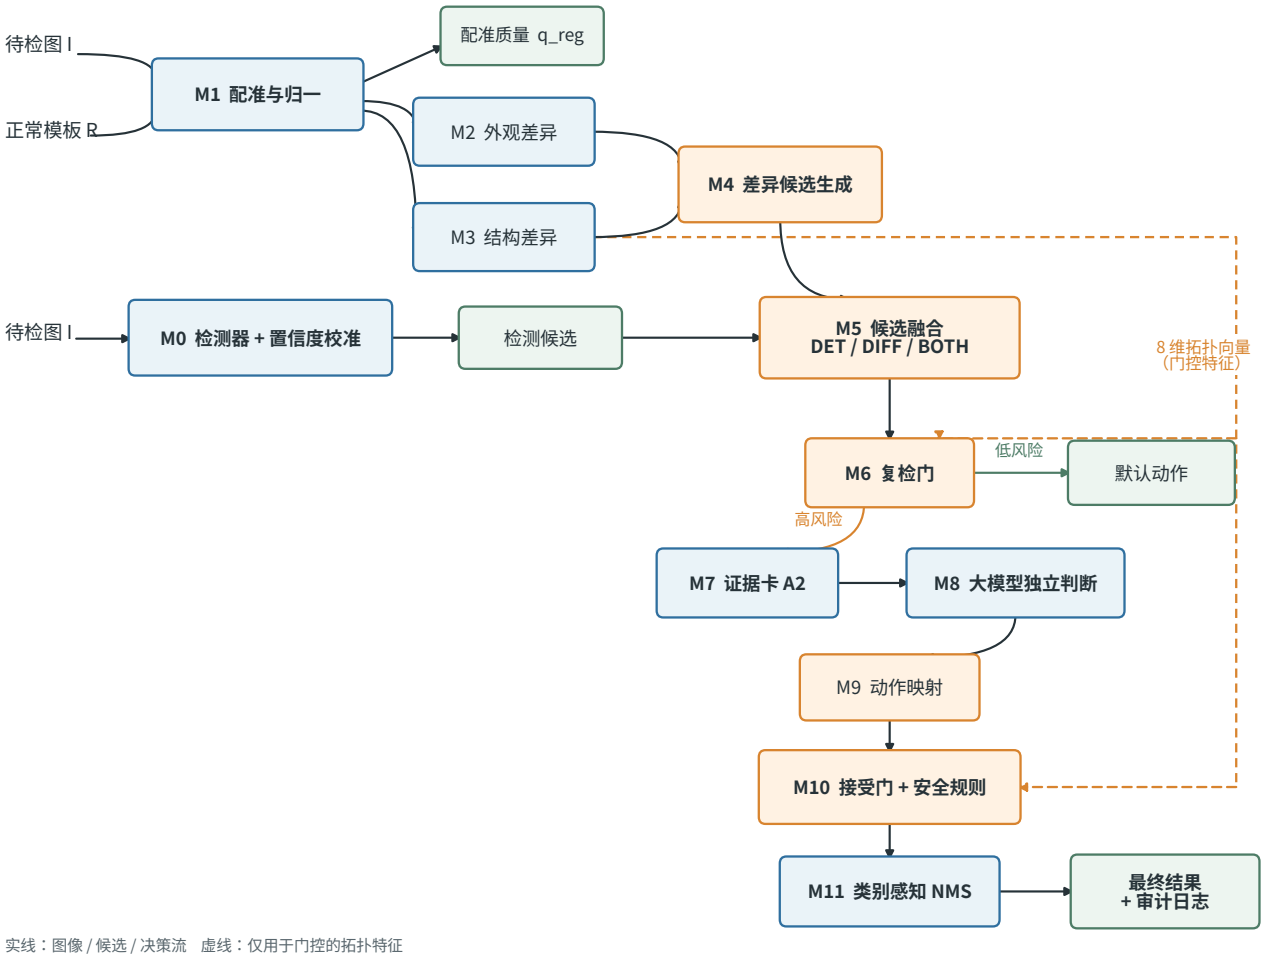


Fig. 1. 基于正常模板与多模态大模型的 PCB 缺陷检测结果复核总体框架。基础检测器与模板差异模块产生双来源候选，复检门选择需要调用验证器的候选，接受门和安全规则约束修改动作，最终经类别感知融合得到检测结果与审计日志。

背景中位差以及变换参数越界程度组成特征向量 z^{reg}，再在验证样本和合成错位样本上校准映射

$$q_{\mathrm{reg}} = g_{\mathrm{reg}}(z^{\mathrm{reg}}). \tag{9}$$

ECC 分支和回退分支由同一质量量纲进入后续模块。q_{reg} 一方面作为复检门和接受门的输入，帮助识别由参考错位产生的高风险候选；另一方面承担安全开关作用，低于阈值时停止执行依赖模板的修改并回退到检测器输出。阶段 E 的扰动实验进一步显示 q_{reg} 随配准扰动下降，说明该分数确实表达参考可靠性，其门控用途在第 5 章展开。

B. 外观差异与拓扑差异（M2、M3）

配准和归一后的图像进入两条互补的差异计算路径。外观路径关注材料强度的增减，拓扑路径关注铜线连通关系的改变。二者在本章只负责形成差异候选和数值特征，不预设其可被多模态大模型正确解释。

外观差异由逐像素绝对差和结构相似性残差加权得到：

$$M_{\mathrm{pix}} = \mathrm{Norm}\big(|\widetilde{I} - \widetilde{R}|\big), \tag{10}$$

$$M_{\mathrm{ssim}} = \frac{1 - \mathrm{SSIM}(\widetilde{I}, \widetilde{R})}{2}, \tag{11}$$

$$M_{\mathrm{app}} = \eta_1 M_{\mathrm{pix}} + \eta_2 M_{\mathrm{ssim}}. \tag{12}$$

绝对差对局部铜缺失、额外铜和孔洞变化响应直接，SSIM 残差补充邻域结构与对比度变化。权重 η_1、η_2 只在验证折选择，不在测试折调节。由于主数据近二值，M_{pix} 已包含较强的材料边界信号，SSIM 的作用主要是把孤立的强度响应组织为局部结构响应，而不是提取自然图像纹理。

拓扑路径先对当前图和对齐模板分别执行 Otsu 阈值分割，经轻量开闭运算清除孤立噪点和小孔后得到铜区域掩码 B_I 与 B_R，再骨架化为 K_I 与 K_R。若直接计算 K_IXOR K_R，不足一个线宽的配准残差也会沿整条线路产生两条平行伪差异。本文在比较前对对方骨架作半径为 δ 的膨胀，定义容差感知 XOR：

$$M_{\mathrm{topo}} = \big(K_I \wedge \neg\,\mathrm{Dilate}(K_R, \delta)\big) \vee \big(K_R \wedge \neg\,\mathrm{Dilate}(K_I, \delta)\big). \tag{13}$$

TABLE II
EviGate-PCB 十二个模块的职责划分

模块	输入	输出	职责
M0 基础检测器	待检图像 I	框、类别、校准置信度组成的 C_{det}	快速提供具有类别语义的初始检测候选，不承担模板比较。
M1 配准与光度归一	I、正常模板 R	对齐模板、配准质量 q_{reg}	统一几何坐标和亮度尺度，量化参考是否可靠，为破坏性动作提供降级依据。
M2 外观差异	I、对齐模板	外观差异图 M_{app} 与区域统计	描述材料增减和灰度变化，仅服务于差异候选与门控特征，不作为 A2 证据卡面板。
M3 结构差异	对齐后的图像对	结构差异图 M_{topo}、八维拓扑向量	计算容差感知的连通性变化；差异图不进入证据卡，拓扑向量作为门控特征。
M4 差异候选生成	M_{app}、M_{topo} 与质量信息	C_{diff}	对差异区域阈值化、过滤和成框，提出可用于恢复漏检的候选假设。
M5 候选融合	C_{det}、C_{diff}	统一候选 C 与来源标记	合并空间一致的候选，标记 DET、DIFF 或 BOTH，并保留动作所需的原框信息。
M6 复检门	检测、差异、拓扑、来源及 q_{reg} 等候选特征	复检风险分数与调用决策	在预算内定位更可能被纠正的候选，决定是否调用多模态验证器。
M7 A2 证据卡	高风险候选、I、对齐模板	三面板视觉证据	生成当前紧裁剪、模板紧裁剪和更大上下文，保持对应位置和缩放一致。
M8 大模型独立判断	A2 证据卡、封闭缺陷知识 K	固定 JSON 视觉判断	在候选范围内判断缺陷存在性和类别，不自由生成框，不直接执行系统动作。
M9 动作映射	验证器输出、候选来源、检测器结果	六类提议动作	在模型外比较独立判断与原检测，把结论映射为 keep、remove、relabel、add、reject 或 defer。
M10 接受门与安全规则	候选证据、提议动作、q_{reg}	执行或回退决策	估计修改是否产生正效用，并以动作阈值、配准约束和合法性规则阻断有害修正。
M11 最终融合	全部已接受动作与默认结果	最终框集合、审计日志	执行动作并进行类别感知 NMS，记录候选来源、模型输出、门控分数及最终决策。

式 (13) 只保留在对方骨架的 δ 邻域中无法找到对应点的结构变化。真实断路、桥接和支路增生仍会保留，轻微横向漂移造成的成对边缘响应则被吸收。容差不是单纯的图像平滑，它显式编码“在允许位置误差内视为同一条线路”的匹配关系。

阶段 E 的 RQ4 鲁棒性实验为该设计提供了直接证据。在 343 个漏检目标上，ECC 配准后采用直接 XOR 仅恢复 $23/343 = 6.71\%$，采用容差 XOR 恢复 $81/343 = 23.62\%$，提升约 3.5 倍；与此同时，正常区域的伪差异 XOR 占比由 0.02892 降至 0.01441，下降 50%。召回增加与伪差异减少同时发生，排除了“仅靠扩大异常区域换取召回”的解释，表明容差膨胀确实抑制了错位噪声并保留了真实结构断裂。（数字来源：阶段 E，RQ4 鲁棒性实验。）

对每个候选区域，M3 还计算八维局部拓扑向量

$$t_i = [\Delta n_{cc}, \Delta n_{end}, \Delta n_{branch}, \Delta\chi, \Delta L, r_{xor}, \Delta A, \Delta P], \tag{14}$$

其中 n_{cc}、n_{end} 和 n_{branch} 分别为连通分量、骨架端点和分叉点数量，χ 为 Euler 数，L 为骨架长度，r_{xor} 为容差 XOR 占比，A 和 P 为铜区域面积与轮廓周长。差值均在当前区域和模板同坐标区域之间计算。该向量不充当六类缺陷的硬规则分类器，而是以连续特征描述断开、连接、孔结构和边界的变化程度。阶段 B2 已否定把拓扑图直接放入证据卡的做法，但不否定这组机器可读特征在风险门控中的作用。

C. 差异候选生成（M_4）

M4 将连续差异图转换为有限数量的候选。阈值估计的关键是限定正常区域，而不是对含缺陷的整图直接取高分位数。设训练折或验证折中的非缺陷像素集合为 Ω_N，外观阈值定义为

$$\tau_{\text{app}} = Q_{1-\alpha}\left(M_{\text{app}}(x) \mid x \in \Omega_N\right), \tag{15}$$

并以相同原则确定拓扑差异阈值。整图分位数会把待检测缺陷本身纳入“正常残差”经验分布。当缺陷面积较大或残差较强时，高分位阈值随缺陷一同升高，最需要保留的像素反而可能落到阈值以下。项目早期用整图 99.5% 分位数时，6 张图仅产生 2 个差异候选；改为正常区域估计后，前序配置在 IoU 为 0.3 时的漏检恢复候选率达到 0.318。这一故障现象说明阈值样本域比名义分位点更重要。（数字来源：阶段 A 前序基线与故障诊断。）

外观和拓扑二值响应采用逻辑或合并：

$$M_{\text{bin}} = \mathbf{1}[M_{\text{app}} > \tau_{\text{app}}] \vee \mathbf{1}[M_{\text{topo}} > \tau_{\text{topo}}]. \tag{16}$$

随后依次执行开运算去除孤立点、闭运算连接相邻响应、孔洞填充，并提取连通域。面积上下界和形状约束作用于连通域掩码，外接框只用于后续匹配与裁剪。这个区分决定了面积参数的含义：候选面积是稀疏差异像素的连通域面积，通常远小于包围这些像素的外接框面积。DeepPCB 的最小标注缺陷为 20×20 px，外接框面积为 400 px^2；若把连通域面积下界也设为 400，最小缺陷即使在框内产生正确响应，也会因差异像素未填满整个框而被过滤。阶段 A 将面积下界由 400 降至 150 后，IoU 0.3 召回极差贡献为 0.328，印证了连通域面积不能按标注框面积设置。（尺寸数字来源：阶段 0 数据实况核查；面积参数结果来源：阶段 A 调参。）

阶段 A 在检测器未参与训练的 val 折完成参数扫描。该折包含 300 张图和 317 个检测器漏检，避免了在训练折上因检测器见过样本而低估漏检分母。推荐配置把项目前序

基线的 IoU 0.3 漏检恢复候选率从 0.318 提高到 0.625，每图噪声候选为 19.25。这一结果证明差异路径能够覆盖检测器未提出框的目标，也表明候选仍然较稠密，必须由后续复检门控制调用成本。（数字来源：阶段 A，val 折差异候选参数扫描。）

参数扫描以每个因素在搜索范围内造成的 IoU 0.3 召回极差衡量敏感性，影响排序为：阈值估计 0.524，面积下界 0.328，形态学操作 0.167，骨架容差 δ 为 0.082，差异图合并方式 0.035。阈值估计的影响最大，与整图分位数被缺陷抬高的故障一致；面积下界位居第二，与连通域和外接框面积不等价的分析一致；容差参数对结构噪声有明确作用，但其影响小于阈值域和小目标过滤。该排序也限定了后续调参优先级，不能仅围绕形态学核或 XOR 半径微调而忽略正常区域建模。（数字来源：阶段 A 参数影响分析。）

每个差异候选保留外观残差均值、最大值和高分位数、超阈值面积占比、拓扑 XOR 面积、式 (14) 的局部向量、与检测框的重叠关系及 q_{reg}。这些属性既用于候选融合，也作为第 5 章学习式复检门的输入。候选生成只要求较高覆盖，不在这一阶段把差异连通域解释为确定缺陷。

D. 候选融合（*M5*）

设基础检测器候选为 C_{det}，差异候选为 C_{diff}。M5 在二者之间构图：若一对框的 IoU 不小于 0.3，或一个框的中心落入另一个按局部尺度扩张后的框，则连接对应节点；连通节点聚为统一候选。仅含检测节点的候选标记为 `DET`，仅含差异节点的候选标记为 `DIFF`，同时获得两类支持的候选标记为 `BOTH`。IoU 阈值 0.3 与漏检候选召回的评价口径一致，中心点规则则处理细长差异连通域与较宽检测框之间重叠偏小但位置一致的情形。

融合过程同时保留检测器原框、差异外接框和供大模型观察的融合上下文框，三者不可互换。对 `BOTH` 候选，大模型可查看覆盖两种来源的融合区域，但 `keep`、`relabel` 和 `remove` 始终作用于检测器原框，避免外观差异掩码的不规则边界或扩张上下文改变最终定位精度。`BOTH` 已包含检测器框，因此不允许再执行 `add`。若检测框与差异框的 IoU 小于 0.1，说明二者只因宽松的中心点规则被聚到一起，空间一致性不足，此时拆回两个独立候选，分别按 `DET` 与 `DIFF` 流程处理。该拆分规则阻止一个远离检测目标的真实差异被错误吸收到原框，也阻止差异噪声借助检测框获得双来源支持。（融合阈值与动作约束来源：开发规格书第 3.6 节。）

这种表示使两条候选路径承担不同职责。`DET` 保留检测器的语义类别和校准置信度，主要覆盖正确检测、误报和错分类；`DIFF` 不携带检测类别，主要提供潜在漏检位置；`BOTH` 表示检测语义与模板变化在空间上相互支持。融合只建立候选级对应关系，不提前决定保留、删除、改类或新增，最终动作由独立判断和安全门共同确定。

E. 证据卡（*M7*）

M7 的最终实现采用三面板 A2 配置，而不是原设想的六面板外观与拓扑证据卡。P1 为当前待检图的候选紧裁剪，P2 为配准后正常模板在完全相同坐标和尺度下的紧裁剪，P3 为带候选位置标记的更大上下文。P1 回答当前位置实际出现了什么，P2 提供该位置正常时应有的结构，P3 防止紧裁剪截断线路走向或把相邻焊盘关系移出视野。三个面板保持固定次序、坐标对应和显示范围，使大模型可以直接比较当前状态与正常反事实。

证据分辨率由数据实况决定。阶段 0 对全部 10013 个缺陷框的统计给出框宽中位数 35 px、框高中位数 33 px。紧裁剪按宽高扩张 1.5 至 2 倍后，局部区域通常只有约 50 至 70 px，若直接排入证据卡，细小缺口和桥接会被缩放与压缩进一步抹平。因此，P1 和 P2 在保持同一插值方式与几何尺度的条件下上采样到 256×256，P3 使用更大的原图上下文但仍显式标记候选位置。上采样不会创造新结构，其作用是避免显示分辨率成为额外瓶颈。（数字来源：阶段 0 缺陷尺度统计。）

外观差异图和拓扑差异图最终不进入证据卡。这一选择不是工程简化，而是阶段 B2 负面结果驱动的设计修订。阶段 B2 在同一候选、提示词骨架和解码设置下进行了 450 次专门对照，存在性 F1 从高到低为：A2 的 0.8082，外观图二值化配置 A6F 的 0.7778，完整六面板配置 A6 的 0.7763，仅增加拓扑图的 A2T 为 0.7481，仅增加数值拓扑摘要的 A2N 为 0.7183。所有外观或拓扑增强变体均低于只包含当前裁剪、正常模板和上下文的 A2，因而不能声称显式差异视觉证据改善了大模型判断。（数字来源：阶段 B2，450 次证据诊断对照。）

阶段 B2 还检查了两个可能使上述结论失真的混淆解释。第一，差异热图并非因逐图自动拉伸而放大微小噪声：实现已将 M_{app} 固定截断到 $[0, 1]$ 后使用固定色标，拓扑图也采用固定三色映射，渲染符合预定规范。第二，结果并非只由某一类低质量配准候选拖累：按 `DET`、`DIFF` 和 `BOTH` 三种来源分别统计时，加入外观差异图的 A3 均低于 A2。固定渲染排除了显示尺度漂移，分来源比较削弱了配准残差污染这一解释。因此，更符合数据的结论是，当前多模态大模型难以从这些人工编码的细粒度差异图中稳定获得额外信息，额外面板还可能分散对当前图与正常模板直接比较的注意力。（结论来源：阶段 B2 混淆因素诊断。）

负面消融并不意味着 M2 和 M3 无效。二者在阶段 A 和阶段 E 已分别证明可用于提出漏检候选和抑制结构伪差异，其机器可读统计仍可进入门控模型。本文据此重新划分信息流：A2 三面板是大模型的视觉证据卡，外观残差统计、八维拓扑向量和 q_{reg} 是复检门与接受门的结构化特征。拓扑证据由“大模型视觉输入”重新定位为“门控特征”，具体使用方式在第 5 章说明。这一修订如实保留了实验否定的部分，也保留了有独立候选召回与鲁棒性证据支持的部分。

V. 分级复检与保守修正

大模型复检同时受到调用成本与修改风险的约束。若对全部候选直接调用大模型，计算开销随候选数线性增长；若将大模型结论直接覆盖检测结果，少量错误判断就可能抵消原检测器已经获得的性能。为此，本文把复检过程拆分为三个职责互不混淆的阶段。复检门 M6 只决定哪些候选值得调用大模型，大模型验证器 M8 只给出独立视觉结论，动作映射 M9 将该结论转换为候选动作，接受门 M10 再判断动作是否应当执行。第一个门优化有限预算下的错误覆盖，第二个门约束修改风险，二者不能由同一阈值替代。

A. 复检门（*M6*）

设候选 c_i 的基础检测结果及外部证据特征为 z_i^{review}。复检门的监督目标不是判断候选处是否存在缺陷，而是预测

TABLE III
阶段 C 复检门的五折 OOF 性能

模型	PR AP	ROC AUC
Logistic	0.1839	0.7909
LightGBM	**0.4311**	**0.9227**

该候选是否包含一个值得大模型介入、并且存在可执行修正路径的错误：

$$y_i^{\text{review}} = \mathbb{I}[c_i \text{ 对应可修复的误报、漏检或错分类}]. \quad (17)$$

该定义把“困难样本”和“可修复错误”区分开来。低置信度的正确检测可能很难判断，却不应占用有限调用预算；高置信度误报或由差异分支发现的漏检候选则可能具有较高修正价值。复检门输出风险分数 $r_i = g_r(z_i^{\text{review}})$，在调用率预算 b 下按 r_i 排序选择前 b 比例的候选。阈值因预算变化，模型本身不读取大模型输出，也不决定任何检测框的增删改。

输入特征覆盖检测器不确定性、候选来源、参考差异和几何属性。检测器侧使用温度校准后的置信度、类别 margin 与预测熵；来源标记采用 DET、DIFF、BOTH 的独热表示，并保留检测框与差异框的重叠信息；外观证据使用残差均值、95 分位数和超过差异阈值的面积比例。结构证据为 8 维拓扑向量，依次描述连通分量、端点、分支点、欧拉数、骨架长度、拓扑异或面积、区域面积和周长的变化。配准质量 q_{reg} 用于表示参考证据的可信程度。框宽、框高和长宽比补充微小目标与细长缺陷的尺度信息。由此得到

$$z_i^{\text{review}} = [p_i^{cal}, m_i, H_i, s_i, a_i, t_i, q_{reg}, w_i, h_i, w_i/h_i], \quad (18)$$

其中 s_i 表示来源及来源间重叠特征，a_i 表示外观残差统计，$t_i \in \mathbb{R}^8$ 表示拓扑向量。拓扑差异图在证据消融后不再作为大模型视觉输入，但其数值向量仍作为门控的结构化特征保留。

本文比较 L2 正则 Logistic 回归与 LightGBM。Logistic 便于解释特征方向，也可作为低复杂度基线；LightGBM 能描述来源、配准质量、外观残差和拓扑变化之间的非线性交互。阶段 C 使用五折 OOF 预测构造了共 51222 个候选，正样本率约为 2.1%。表 III 给出跨折汇总结果。LightGBM 的 PR AP 为 0.4311，ROC AUC 为 0.9227；Logistic 的对应结果为 0.1839 和 0.7909。LightGBM 的 PR AP 是 Logistic 的约 2.3 倍。由于负样本占绝对多数，ROC AUC 容易受到大量真负例支撑，PR AP 更直接反映门控对少数可修复错误的排序能力。这组结果说明线性打分不足以刻画极端不平衡条件下的候选风险，因而本文将 LightGBM 作为主模型，将 Logistic 保留为可解释对照及 RQ3 曲线中的既有实现。

B. 大模型验证器（*M8*）与动作映射（*M9*）

大模型验证器采用去锚定输入原则。模型查看当前候选裁剪、局部上下文和对齐后的正常参考裁剪，不读取检测器类别、检测器置信度和系统期望动作。该约束使模型先回答视觉问题，再由系统比较其结论与检测结果，减少围绕检测器原结论生成解释的倾向。大模型也不能在整幅图像中自由搜索缺陷，只能验证由 DET、DIFF 或 BOTH 分支给出的候选区域，因此整个问题保持为封闭候选验证。

缺陷类别被限制为数据集定义的六类：open、short、mousebite、spur、pinhole 和 spurious_copper。存在性只能取 true、false 或 null，类别字段在六类之外只允许 normal 与 uncertain。参考可靠性、外观模式、拓扑模式、证据强度及原因码均使用固定枚举。输出必须符合预先冻结的 JSON schema，核心字段包括 defect_present、predicted_class、reference_reliability、appearance_pattern、topology_pattern、evidence_strength 和 reason_codes。固定 schema 不只是工程上的格式偏好。自由文本对照的 JSON 可解析率为 0.0000，意味着后续动作映射、接受特征构造和审计记录均无法稳定执行。主实验因此采用结构化输出；解析失败或字段越界一律标记为无效，不从自然语言中猜测动作。

TABLE IV
候选来源与独立结论的动作映射

来源	独立结论	提议动作
DET/BOTH	normal	remove
DET/BOTH	缺陷且类别相同	keep
DET/BOTH	缺陷且类别不同、证据一致	relabel
DET/BOTH	uncertain	defer/keep
DIFF	缺陷	add
DIFF	normal	reject
DIFF	uncertain	reject/defer

M9 在大模型外部执行确定性映射，规则见表 IV。DET 和 BOTH 表示候选包含基础检测框。若独立结论为 normal，则提议 remove；若结论为缺陷且类别与检测器一致，则 keep；若类别不同、类别非 uncertain 且拓扑证据支持新类别并反驳原类别，才提议 relabel；无法形成确定结论时 defer。DIFF 候选不依附已有检测框，独立结论为受支持缺陷时才提议 add，normal 时 reject，不确定时 reject 或 defer。BOTH 候选已有检测框覆盖，不能通过 add 再生成重叠框。大模型只负责描述独立视觉结论，系统侧映射负责把结论解释为对检测集合的操作，从接口上隔离视觉判断与最终修改权限。

动作优先级由五折基础检测错误分解决定。全部可纠错空间包含漏检 947 个、误报 636 个和错分类 61 个，比例分别为 57.6%、38.7% 和 3.7%。因此 prompt 首先要求判断候选处是否存在受支持缺陷，优先服务 DIFF 候选的 add 路径与 DET/BOTH 候选的 remove 路径。relabel 的理论收益上限最小，且错误类别判断容易把一个位置正确的检测转化为错分类，故其触发条件同时要求封闭类别、非 uncertain 结论与类别拓扑一致性。该设计不是均匀处理三类动作，而是根据真实错误空间分配判断能力和风险额度。

prompt 版本实验揭示了存在性准确率与 remove 可用性之间的冲突。v1 的缺陷存在性 F1 为 0.7678，高于 v2 的 0.7347；v1 的 normal 判定率为 0.31，低于 v2 的 0.39。提高模型对 normal 的敏感度有助于识别误报，却会降低整体存在性 F1，两个目标不能同时由单一 prompt 最大化。remove 路径尤其依赖 normal 结论，因为 DET/BOTH 候选只有在模型否定缺陷时才会提出删除。早期 smoke 实验中，v1 的 normal 判定率为 0.000，导致 remove 路径完全不可用。后续版本提高 normal 引导并接受存在性 F1 的下降，目的不是宣称 v2 全面优于 v1，而是恢复双向纠错能力。论文同时报告两个指标，以免用单一 F1 掩盖动作分布改变。

C. 接受门（*M10*）与安全规则

复检门放行只表示候选值得查看，大模型给出动作也不表示该动作安全。接受门对每个提议动作预测其执行后是否产生正效用。给定当前预测集合 $\hat{Y}$、真值 Y^* 和动作 a_i，训练标签定义为

$$y_i^{\text{accept}} = \mathbb{I}\Big[U(\hat{Y} \oplus a_i, Y^*) > U(\hat{Y}, Y^*)\Big], \qquad (19)$$

其中 $\oplus$ 表示执行动作。候选级实现中，删除原始误报、将已匹配位置改为正确类别、添加一个匹配原漏检真值的差异框分别构成 remove、relabel、add 的正效用标签；会损害检测结果或没有改善的修改均为负例。

不同动作的样本机制、风险和正例率差异很大，故接受门按 remove、relabel、add 分开训练，而不是把动作独热编码后混合拟合一个分类器。输入在复检特征基础上加入大模型存在性与类别结论、证据强度、参考可靠性、外观一致性、拓扑一致性和 JSON 有效标记。最终执行条件为

$$\text{Apply}(a_i) = \mathbb{I}[g_{a_i}(z_i^{\text{accept}}) \geq \tau_{a_i}] \wedge \text{SafetyRule}(a_i), \quad (20)$$

其中 g_{a_i} 是动作专属接受模型，τ_{a_i} 是动作阈值。模型概率只提供统计证据，不能绕过硬安全规则。

阶段 C 的五折训练分布验证了分动作建模的必要性。remove 每折约 800 个样本，正样本为 26 到 46 个；add 每折约 12000 个样本，正样本为 39 到 55 个。两者虽都高度不平衡，仍包含可用于估计正负边界的样本。relabel 每折约 2300 个样本，却只有 0 到 5 个正样本，fold3 的正样本数为 0，其余折也仅为 5。全数据只有 61 个错分类，经过折隔离和动作提议筛选后无法支持稳定的 relabel 接受模型。这是训练数据本身给出的限制，不能用类别权重或过采样掩盖。fold3 因标签单一触发保守退化，relabel 模型不输出可接受概率，系统拒绝该动作。其他折即使能形式上拟合，也必须服从更高门槛和拓扑一致性检查。

硬安全规则从动作后果出发设置。remove 会不可逆地丢弃已有检测，阈值设为三类动作中最高，且只能作用于 DET 或 BOTH 候选。relabel 只能在封闭的六类标签内执行，大模型类别与拓扑模式必须一致，来源也必须包含原检测框。add 只能采用已有 DIFF 候选的确定性边界，不允许大模型自由生成坐标；BOTH 候选因已被检测框覆盖而不能 add。配准质量 q_{reg} 低于阈值时，正常参考与差异证据不可信，remove、relabel、add 等破坏性或参考驱动动作全部禁止。JSON 解析失败、字段非法或动作冲突时回退到默认结果，即保留基础检测器输出或将候选交由人工处理。

训练不足时的兜底方向直接决定最坏情况风险。若样本少于最低要求或训练标签单一，接受概率固定回退为 0，拒绝一切修改，而不是把未知模型解释为全部接受。早期实现曾在训练不足时采用接受式退化，使大模型错误可以直接进入最终结果，最差情况比基础检测器更差。保守退化将系统返回到未修改基线，其代价是暂时放弃潜在收益，但保证数据不足不会自动扩大伤害。该规则对 relabel 尤其关键，因为 fold3 没有任何正例可供训练。

D. 防泄漏与门控训练协议

数据按 PCB 模板组执行五折 GroupKFold，同一模板的旋转图和衍生图不能跨越训练与测试边界。第 i 折以该折图像为 test，以第 $(i+1) \bmod 5$ 折为 val，其余三折训练检测器。五折本身已经覆盖全部 1500 张图，每张图恰好在一折中作为 test，且产生该图预测的检测器从未见过该图。将五个 test 折的输出拼接即可得到完整 OOF 候选集合，不需要再在每个外层折中嵌套检测器交叉拟合。

这一协议把检测器训练次数从两层折叠可能需要的 20 次降为 5 次，同时保持每条门控训练记录来自样本外预测。它与“先用全数据训练检测器再构造门控标签”有本质差别，后者会让门控看到过于乐观的检测分数和错误分布。温度校准、工作点选择和 prompt 定稿均使用对应 val 折，不接触当前 test 折。

门控层再执行一次按折隔离。评价第 i 折时，复检门与三个动作接受门只能使用其他四折的 OOF 候选及其标签训练，当前第 i 折只用于排序、调用和最终评价。形式化地，门控训练集为 $\mathcal{D}_g^{(-i)} = \bigcup_{j \neq i} \mathcal{D}_{\text{OOF}}^{(j)}$，评价集为 $\mathcal{D}_{\text{OOF}}^{(i)}$。所有候选特征、正效用标签和阈值选择均遵守这一边界。最终报告汇总五个互斥评价折，从而避免检测器预测泄漏和门控标签泄漏叠加造成的虚高结果。

接受门的动作提议训练样本由冻结的确定性证据代理生成，以节省大模型调用。该选择保持折间隔离，但会形成代理动作与真实大模型动作之间的训练分布偏移。因此，当前协议能够检验门控的风险控制能力，却不能把接受概率解释为对任意大模型输出都已充分校准。部署时应持续记录真实提议，并在样本充足后按同一折隔离原则重训动作模型；样本不足期间继续采用拒绝式保守退化。

E. 分级复检的成本收益

RQ3 在 5%、10%、20%、40%、60% 和 100% 六个调用预算上比较候选选择与动作接受策略。复检门是否有效，应在相同调用率下考察其覆盖了多少真实可修复错误，而不是只比较被调用候选的平均置信度。5% 调用预算下，RQ3 中采用的 Logistic 复检门取得 0.4649 的错误候选复核召回，随机选择仅为 0.0315。两者调用数量相同，学习式排序找到的可修复错误是随机策略的 14.8 倍。这说明检测置信度、来源、外观残差、拓扑向量和配准质量的组合确实能把纠错机会集中到预算前端。相应地，有害修正率 HCR 从随机策略的 0.9633 降至 0.6813。0.6813 仍然偏高，表明更好的候选选择不能代替动作级保护，但它已显著减少无效或危险调用进入后续链路的比例。图 2 展示了 HCR 随调用预算的变化。

接受门的价值体现在预算增加时不发生性能退化。若大模型提议未经接受门筛选，最终 F1 从 5% 预算下的 0.9088 下降到 20% 时的 0.9015、60% 时的 0.8820，并在 100% 调用时降至 0.8660。调用越多，错误提议累积越明显，全量复检反而比低预算复检更差。加入接受门后，F1 在 5%、20%、60% 和 100% 预算下分别为 0.9117、0.9115、0.9115 和 0.9115，完整预算范围稳定在 0.9115 至 0.9117。接受门没有把大模型调用次数本身当作收益，而是把每个提议视为需要重新证明的修改。图 3 中，无接受门曲线随预算持续下降，双门控曲线则保持在基础检测器水平附近。

安全性并不消除推理成本。真实大模型调用的每候选平均时延为 29.1 秒，P95 为 41.4 秒。调用预算从 5% 增至 100% 时，平均每图 token 消耗从 123 增至 2519，接近随预算线性增长。因此，100% 调用既带来最高成本，也在无接受门时产生最低 F1；低预算复检门负责压缩调用量，接受门负责阻断调用后的错误修改，二者分别作用于成本与风险。

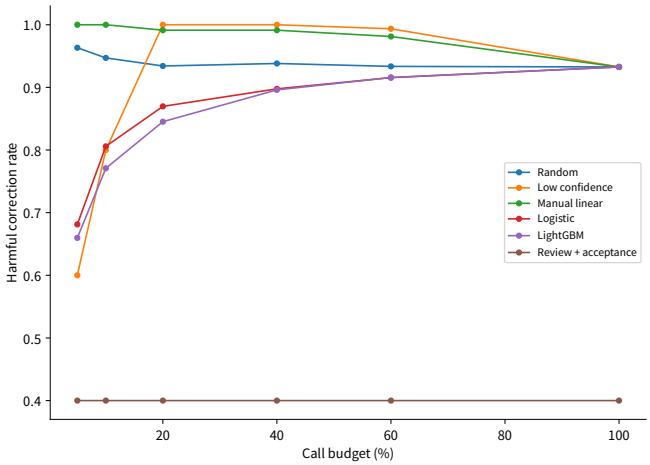


Fig. 2. 不同调用预算下的有害修正率。学习式复检排序在低预算区间优于随机选择，接受门进一步阻断高风险动作。

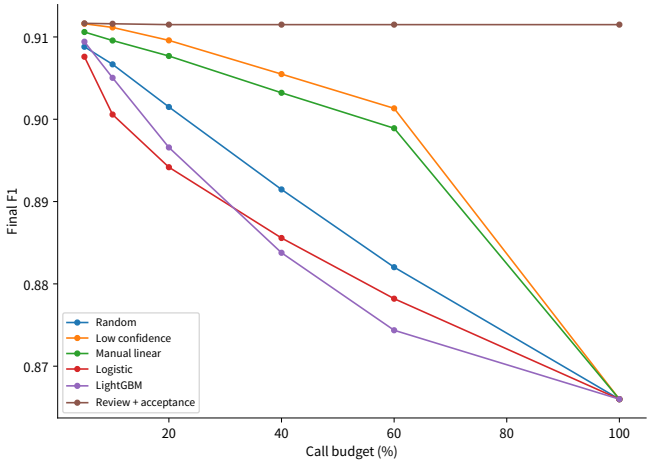


Fig. 3. 调用预算与最终 F1 的关系。缺少接受门时，增加调用会累积错误动作；采用接受门后，各预算点保持稳定。

这组曲线给出了分级复检的核心经验结论。复检门在 5% 预算下以 14.8 倍于随机策略的效率定位纠错机会，证明有限调用应优先分配给结构化风险最高的候选；接受门把无保护流程从 0.9088 到 0.8660 的预算退化，转化为 0.9115 至 0.9117 的稳定区间。当前大模型的实际净增益仍受判断质量限制，但双门控已经实现更基础的系统目标：预算增加不能成为性能下降的原因，训练证据不足不能成为放宽修改权限的理由。

VI. 实验设计、结果与分析

本章围绕四个研究问题展开实验。RQ1 考察不同视觉证据是否能提高多模态大模型的候选级判断能力，RQ2 检验复核系统能否在完整检测流程中纠正误报、漏检和错分类，RQ3 分析复检门与接受门在不同调用预算下的效率和可靠性，RQ4 考察配准扰动、差异表示以及检测器替换对系统行为的影响。除专门说明的候选级诊断实验外，主结果均来自按模板组隔离的五折测试。本文同时报告正面发现、统计上不显著的结果和性能退化，避免以单个折或单个预算点替代整体结论。

TABLE V
接受门对预算曲线的影响

调用预算	无接受门 F1	有接受门 F1
5%	0.9088	0.9117
20%	0.9015	0.9115
60%	0.8820	0.9115
100%	0.8660	0.9115

A. 实验设置

1) 数据集及严格划分: 实验采用 DeepPCB 数据集 [3]。按仓库中的实际列表文件和图像文件核查，数据集包含 1500 对待检图与正常模板图，其中官方 `trainval` 为 1000 对，官方 `test` 为 500 对。全部图像均为 640×640 像素的 JPEG 图像，主体为单通道灰度图。1500 个标注文件共包含 10013 个缺陷框，类别为 open、short、mousebite、spur、spurious copper 和 pin-hole 六类。每幅图的缺陷框数中位数为 7，缺陷框宽度和高度的中位数分别为 35 和 33 像素，说明候选级复核面对的是局部细粒度目标，而不是整图级显著异常。

官方划分不能直接支撑本文的主结论。数据目录可以稳定还原 11 个模板组，其中 7 个模板组同时出现在官方 `trainval` 和 `test` 中。换言之，同一模板组的板图可能分别进入训练集和测试集，检测器能够从训练图像中接触与测试图像共享的板级结构。这样的组间泄漏会低估跨模板泛化难度，并可能抬高检测和复核结果。本文据此将官方划分仅作为与既有结果对照的参考，不用它形成方法有效性的主结论。

主实验采用 `GroupKFold` 五折划分，以模板组作为不可拆分的分组单元。第 i 折的测试组在该折的训练和验证数据中完全不可见，验证集取下一折，其余三折用于训练检测器。评价第 i 折的门控模型时，只使用其余折产生的折外候选训练，防止门控阶段重新引入样本泄漏。11 个模板组的规模从 14 对到 325 对不等，最大组与最小组相差 23.21 倍，因此各折样本量不能强行等分。表 VI列出了实际测试组成，五折共覆盖 1500 对图像，每个图像对恰好作为测试样本一次。

2) 基础检测器与多模态验证器: 基础检测器采用 YOLOv8s。每折在三个训练折上训练，在独立验证折上选择 F1 最优工作点，并在测试折上输出折外预测。低置信度阈值 0.001 只用于计算 mAP，不用于报告部署工作点的 Precision、Recall 和 F1。五折检测器的 mAP@0.5 为 0.9580 ± 0.0164，mAP@0.5:0.95 为 0.7135 ± 0.0407；验证集选定工作点上的 Precision、Recall 和 F1 分别为 0.9264 ± 0.0291、0.8964 ± 0.0469 和 0.9105 ± 0.0312。折间 F1 从 0.8721 到 0.9522，表明严格模板隔离后不同板型仍有明显难度差异，报告均值的同时必须保留标准差。

多模态大模型作为候选级验证器，只接收已经定位并放大的证据卡，不在整幅图上自由生成检测框。主后端为本机 Codex CLI，模型为 `gpt-5.6-sol`，推理强度设为 low 并采用确定性解码。输入由当前紧裁剪、正常模板和上下文组成，输出通过 JSON Schema 约束为固定字段；解析失败时系统保持基础检测结果。默认协议隐藏检测器类别和置信度，大模型先独立判断缺陷是否存在及其类别，系

TABLE VI
按模板组隔离的五折测试集组成

折	测试模板组	图像对数	占全部数据比例
fold_0	group20085	325	21.67%
fold_1	group00041、group50600	300	20.00%
fold_2	group12300、group13000	314	20.93%
fold_3	group12000、group12100、group44000	260	17.33%
fold_4	group77000、group90100、group92000	301	20.07%
合计	11 个模板组	1500	100.00%

统再将判断映射为 keep、remove、relabel 或 add。keep、remove 和 relabel 始终作用于检测器原框，add 只能接受已有差异候选，因而大模型没有任意造框权限。所有响应按候选、证据配置、模型和解码参数缓存，累计真实调用约 7000 次。12 路并发下实测吞吐上限约 26 次每分钟，单候选平均墙钟时间约 29 秒，说明选择性调用是工程必要条件，而不只是算法附加项。

3) 评价指标与统计方法: 常规检测指标包括 Precision、Recall、F1、mAP@0.5、mAP@0.5:0.95 和各类别 AP。为直接衡量复核动作，本文定义五个纠错指标。设基础检测器的误报、漏检、错分类和正确检测数量分别为 N^0_{FP}、N^0_{FN}、N^0_{MC} 和 N^0_{TP}，则误报修正率 FPCR 为正确删除的原始误报数除以 N^0_{FP}，漏检恢复率 MDRR 为新增匹配的原始漏检数除以 N^0_{FN}，类别修正准确率 MCCA 为正确重分类数除以 N^0_{MC}。正确检测保留率 TPRR 定义为复核后仍正确的原始 TP 数除以 N^0_{TP}。有害修正率 HCR 定义为降低检测效用的已接受修改数除以全部已接受修改数。TPRR 刻画系统是否破坏原本正确的检测，HCR 则刻画每次实际修改的风险，两者共同约束“敢不敢改”。

成本指标包括大模型调用率、每图调用次数、单候选平均时延和 P95 时延、每图输入 token 数以及配准失败回退率。RQ1 对同一批候选比较不同证据配置，置信区间使用按图像聚类的 bootstrap 计算，以免把同一图像中的多个候选误当作相互独立样本。RQ2 对 Full 与基础工作点进行 2000 次按图像聚类的配对 bootstrap。端到端指标以五折均值和总体标准差报告，所有门控阈值均由验证折选择并在测试前冻结。

B. 可纠错空间分析

在评价复核方法之前，需要先确定基础检测器留下了哪些错误。本文按 IoU 匹配和类别一致性将工作点输出分解为正确检测、错分类、误报、漏检和纯定位错误。纯定位错误表示检测器已经对目标作出响应，但定位未达到正式匹配阈值；它与三类可通过删除、新增或重分类动作直接处理的错误分开统计。表 VII给出五折结果。

可纠错空间定义为错分类、误报和漏检之和，共 1644 项。漏检 947 项，占 57.6%，是最大错误来源；误报 636 项，占 38.7%；错分类仅 61 项，占 3.7%。这个分布决定了后续方法的主战场。只复核检测器已经提出的框，最多能够处理误报和错分类，却无法触及超过一半的潜在纠错空间。差异候选的主要价值因此是提出检测器未覆盖的位置，再由验证器决定是否新增。相对地，重分类动作即使达到很高成功率，对总体 F1 的上限贡献也会受 3.7% 的错误基数限制。

折间分布同样不均衡。fold_0 有 335 个漏检和 216 个误报，可纠错空间为 557；fold_2 只有 180 项可纠错错误，其中误报仅 24 个。若只选一个容易折，复核收益和风险都可能被错误估计。五折隔离不仅防止模板泄漏，也使方法必须面对不同的误报与漏检构成。后续 RQ2 的 Oracle 分析使用完整固定候选集计算候选覆盖上界，从而把“没有提出候选”和“候选已提出但大模型判断错误”区分开来。

C. RQ1: 证据消融

RQ1 固定候选、模型、提示词骨架和解码参数，只改变证据卡内容。A0 仅给当前紧裁剪，A1 加入上下文，A2 进一步加入配对正常模板，A3 加入外观差异，A4 加入拓扑差异，A5 和 A6 继续组合完整证据。七组主消融以及四组附加对照均在相同的 200 个候选上评价。候选级任务判断候选位置是否存在真实缺陷，F1 相对 A0 的差值按图像聚类 bootstrap 给出 95% 置信区间。该诊断集用于比较证据，不用于估计自然部署时的缺陷发生率。

表 VIII显示，A2 相对 A0 提高 0.1178，置信区间为 [+0.0259,+0.2304]，正常模板是具有明确统计支持的关键增量。A3 和 A4 相对 A0 也显著，但它们没有超过仅加入模板的 A2。堆叠更多证据的 A5 和 A6 分别提高 0.0704 和 0.0972，其置信区间均跨越 0，不能宣称相对 A0 有稳定增益。结果否定了“证据越多，大模型判断越好”的简单假设。当前图像与正常模板构成直接反事实参照，连续热图、拓扑图和文字说明则可能增加视觉负担或诱发保守判断。

为排查外观热图的负贡献是否由渲染自动拉伸或配准残差造成，阶段 B2 在同一批 150 个候选上完成 450 次新调用。A2N 保留当前裁剪、模板和上下文，只增加数值摘要；A2T 只增加固定颜色的拓扑差异图；A6F 将外观图改为按预先冻结阈值生成的二值图。实现核查确认原外观图使用全样本统一的 $[0,1]$ 色标，并不存在逐样本最小最大值拉伸。表 IX中三个专门对照均低于同批候选上的 A2，最高的 A6F 也低 0.0304。数值摘要没有产生增益，二值化也没有挽回完整证据卡，因而不能把负结果归结为单一显示错误。

四组附加对照进一步暴露了提示协议的影响。表 X中，去掉“配准不可靠”警告的 A6_no_reg_warning 取得最高 F1 0.8000，说明该警告没有带来预期的稳健性，反而可能让模型过度输出 normal 或 uncertain。向大模型提供检测器标签的 A6_label_aware 达到 0.7701，高于隐藏标签的 A6 0.7347，因此本实验没有证明去锚定优于标签可见协议。旧提示词 A6_prompt_v1 达到 0.7678，但其 normal 判定率为 0.31，低于新版的 0.39，表明提示版本同时改变了判定倾向。自由文本 A6_free_text 的 F1 为 0.6813，JSON 可解析率为 0，依赖后处理启发式才能得到结果，固定 Schema 对可执行复核流程不可缺少。

TABLE VII
五折基础检测器错误分解

折	TP	错分类	误报	漏检	纯定位错误	可纠错空间
fold_0	2085	6	216	335	2	557
fold_1	1987	9	166	77	1	252
fold_2	1894	8	24	148	1	180
fold_3	1608	23	134	118	10	275
fold_4	1408	15	96	269	9	380
合计	8982	61	636	947	23	1644

TABLE VIII
RQ1 主证据消融结果，$n = 200$

配置	证据设置	F1	相对 A0	95% 置信区间	显著性
A0	仅当前裁剪	0.6375	0.0000	基准	不适用
A1	加上下文	0.7033	+0.0658	[+0.0007, +0.1244]	边界显著
A2	加正常模板	0.7553	+0.1178	[+0.0259, +0.2304]	是
A3	加外观差异	0.7380	+0.1005	[+0.0304, +0.1920]	是
A4	加拓扑图	0.7571	+0.1196	[+0.0280, +0.2390]	是
A5	组合证据	0.7079	+0.0704	[-0.0168, +0.1821]	否
A6	完整证据卡	0.7347	+0.0972	[-0.0012, +0.2254]	否

TABLE IX
阶段 B2 专门对照结果，$n = 150$

配置	F1	uncertain 率	JSON 解析率
A2	0.8082	0.1067	1.0000
A2N	0.7183	0.1133	1.0000
A2T	0.7481	0.2400	1.0000
A6F	0.7778	0.1800	1.0000
A6	0.7763	0.1133	1.0000

TABLE X
RQ1 四组附加对照

配置	F1	JSON 解析率
A6_no_reg_warning	0.8000	1.0000
A6_label_aware	0.7701	1.0000
A6_prompt_v1	0.7678	1.0000
A6_free_text	0.6813	0.0000

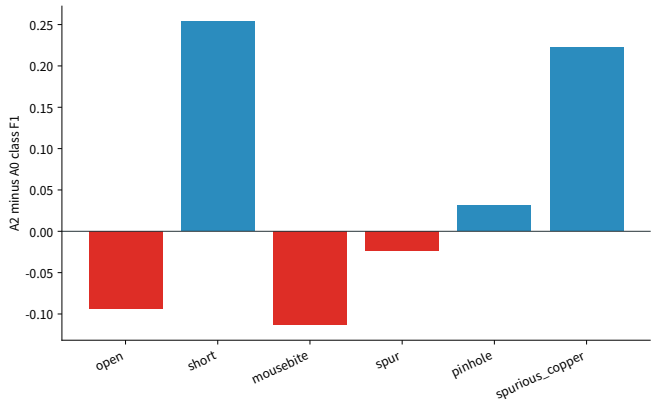


Fig. 4. 不同证据配置的逐类别候选判断增益

图 4给出六类缺陷上的证据增益。类别结果并未呈现“完整证据在各类上一致占优”的模式，宏平均性能也受类别混淆影响。基于这些结果，RQ2 和 RQ3 固定采用 A2，只向大模型展示当前紧裁剪、正常模板和上下文；8 维拓扑向量保留为复检门和接受门的结构化特征，不再宣称它作为大模型视觉输入能带来增量。RQ1 的结论是正常模板有效，而完整外观与拓扑证据卡未被当前候选级实验支持。

D. RQ2：端到端纠错

RQ2 比较八种端到端设置。B0 以 0.001 低阈值保留完整检测排序，只用于 mAP 参考；B1 是验证集选择的检测器工作点；B2 只使用 ECC、SSIM、形态学差异候选和冻结拓扑规则，不调用大模型；B7 对抽样候选全量复检且不使用门控；B8 采用手工线性风险门；Full 采用学习式 Logistic 复检门、分动作接受门和安全规则。Oracle-C 在完整固定候选集上按真值选择最优动作，反映候选覆盖上界；Oracle-A 只在已有真实大模型输出的候选中接受正效用动作，反映当前大模型提议集合的接受上界。

五折固定候选共 51222 个，超过既定调用上限。实验在每折按原始错误类型和候选来源比例分层抽样 800 个候选，共调用评价 4000 个候选；未抽中的候选保持 B1 输出。抽样比例从 fold_0 的 5.5348% 到 fold_4 的 12.5156%。所有方法共享同一批 A2 响应，因而 B7、B8 和 Full 之间的差异来自门控而非调用样本变化。表 XI报告五折均值与标准差。

B2 的 F1 只有 0.0014，说明确定性差异规则不能单独替代检测器。无门控 B7 把 F1 从 B1 的 0.9118 降至 0.8660，同时 HCR 达到 0.9326，即绝大多数被执行的修改降低了检测效用。手工线性门 B8 的 F1 为 0.8787，仍明显低于 B1，HCR 甚至为 0.9607。大模型输出若缺少动作级安全约束，不是可靠的后置纠错器。

Full 的 F1 为 0.9117 ± 0.0343，与 B1 的 0.9118 ± 0.0344 几乎相同。按图像聚类的配对 bootstrap 给出总体 F1 差值 -0.000064，95% 置信区间为 $[-0.000273, +0.000094]$，区间跨越 0。该结果意味着完整流程没有获得统计可辨别的端到端净提升，不能将小数点后波动表述为性能改进。Full 的 TPRR 达到 0.9998，表明学习式双门控基本保留了原始正确检测，但 HCR 均值 0.4000 的折间标准差为 0.5477。其原因是实际接受动作极少，个别折的一次有害动作会使

TABLE XI
RQ2 五折端到端结果

方法	F1	mAP@0.5	TPRR	HCR
B0†	0.2871 ± 0.0813	0.9491 ± 0.0205	不适用	不适用
B1	0.9118 ± 0.0344	0.8813 ± 0.0575	不适用	不适用
B2	0.0014 ± 0.0011	0.0001 ± 0.0002	不适用	不适用
B7	0.8660 ± 0.0368	0.8246 ± 0.0655	0.9572 ± 0.0174	0.9326 ± 0.0280
B8	0.8787 ± 0.0471	0.8450 ± 0.0867	0.9717 ± 0.0305	0.9607 ± 0.0456
Full	0.9117 ± 0.0343	0.8810 ± 0.0573	0.9998 ± 0.0003	0.4000 ± 0.5477
Oracle-C	0.9555 ± 0.0254	0.9106 ± 0.0471	不适用	不适用
Oracle-A	0.9143 ± 0.0336	0.8826 ± 0.0573	1.0000 ± 0.0000	0.0000 ± 0.0000

†B0 使用 0.001 低阈值保留检测排序，其 F1 只描述该阈值下的输出，不作为部署工作点结论。

TABLE XII
FULL 候选级错误转移计数

原始类型	保持正确	已纠正	未纠正	误删
误报	0	1	47	0
漏检	0	0	36	0
错分类	0	0	6	0
正确检测	732	0	0	2

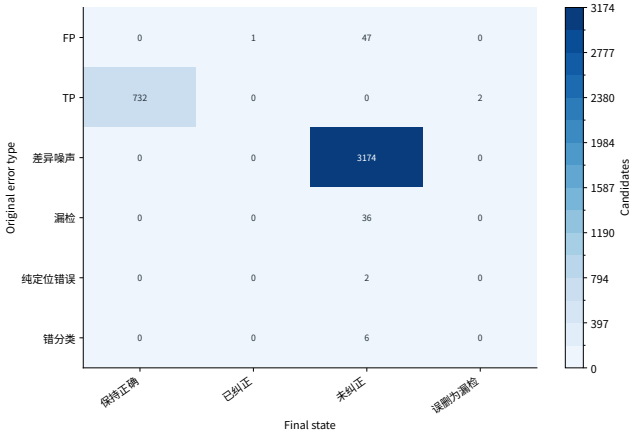


Fig. 5. Full 方法的候选级错误转移热图

该折比率发生大幅变化。安全性应结合绝对动作计数解释，而不能只看比率。

图 5和表 XII完整呈现了错误转移。48 个原始误报中只纠正 1 个，47 个未纠正；36 个漏检没有恢复；6 个错分类没有修正；734 个原始正确检测中 732 个保持正确，2 个被误删。另有 3174 个差异噪声候选和 2 个纯定位错误均未被纠正。Full 未发生误改类别、差异候选新增误报或将错误类别改成另一错误类别，实际损失全部来自 2 次误删 TP。这个结果同时包含安全收益和纠错失败：双门控阻止了绝大多数有害修改，但也几乎没有放行有效修正。

Oracle 结果用于定位瓶颈。Oracle-C 达到 F1 0.9555，相对 B1 保留约 0.044 的提升空间，说明固定候选集能够覆盖足够多的潜在纠错目标，候选生成并非首要上限。Oracle-A 在给定真实大模型输出后只接受正效用动作，F1 也仅为 0.9143，相对 B1 提高 0.0025。即使把接受决策设为理想状态，当前大模型提出的正确修改仍不足以接近候选上界。因此，B1 与 Oracle-C 之间的大部分空间在大模型判断阶段消失，而不是被复检门或接受门截断。RQ2 的结论是双门控实现了接近不退化的安全目标，但端到端净收益为零附近，主要瓶颈在当前多模态大模型对工业细粒度缺陷的判断质量。

E. RQ3: 门控效率与可靠性

RQ3 在 RQ2 的同一批 A2 缓存上离线回放六种策略和六个预算点。预算为每折 800 个抽样候选中的调用比例，分别取 5%、10%、20%、40%、60% 和 100%。random 为固定随机种子抽样，low_confidence 按检测置信度排序，manual_linear 使用手工线性风险分数，logistic 和 lightgbm 使用学习式复检分数排序，review_acceptance 在 logistic 排序后执行接受门与安全规则。表 XIII列出全部 36 个组合的五折均值，RR 表示错误候选复核召回率。

复检门的排序效率在低预算区间最清楚。5% 预算下，logistic 复检门覆盖 46.49% 的错误候选，随机策略仅覆盖 3.15%，前者约为后者的 14.8 倍。LightGBM 在同一预算达到 62.36%，但 Full 按实验前声明固定使用 Logistic 主模型，未根据测试结果事后更换。低置信度策略在 5% 和 10% 预算下的错误候选复核召回均为 0，说明检测置信度不能替代针对“是否值得复核”训练的风险分数。复检门解决的是把有限调用集中到潜在可纠错位置，而不是直接保证大模型修改正确。

接受门决定预算扩大后是否退化。以不使用接受门的随机回放为例，F1 随预算从 5% 时的 0.9088 下降到 100% 时的 0.8660，累计下降 0.0428；20% 和 60% 预算分别为 0.9015 和 0.8820。加入接受门后，F1 从 5% 时的 0.9117 到 20%、60% 和 100% 时均约为 0.9115，接近 B1。接受门因此把“更多调用”与“更多有害执行”解耦。该稳定性不代表大模型判断变好，而是多数提议没有被执行。HCR 维持 0.4000 也应结合 RQ2 的极少接受动作解释，不能把它当成充分校准的概率保证。

调用成本随预算近似线性增加。六种策略在相同预算下调用数一致，每图调用次数从 5% 预算的 0.1341 ± 0.0118 增至 100% 预算的 2.6821 ± 0.2363。真实缓存记录给出的单候选平均时延约 29.1 秒，跨策略与预算的 P95 最高约 41.4 秒。每图输入 token 数从 logistic 在 5% 预算下的 123.35 ± 10.64 增长到 100% 预算下的 2518.81 ± 223.24。在当前后端吞吐下，全量复检既降低 F1 又显著增加成本，低预算复检门与保守接受门是可部署流程的必要组成。

图 6给出 F1、HCR 与调用率曲线，图 7展示接受门可靠性。曲线的核心关系是复检门提高错误覆盖效率，接受门控制实际动作风险。两道门的任务不能合并：只有复检门时，高风险候选虽然更快被找到，但大模型的大量错误提

TABLE XIII
六种门控策略在六个调用预算下的结果，数值为五折均值

策略	指标	5%	10%	20%	40%	60%	100%
random	F1	0.9088	0.9067	0.9015	0.8915	0.8820	0.8660
	HCR	0.9633	0.9471	0.9342	0.9382	0.9335	0.9326
	RR	0.0315	0.1322	0.2251	0.3951	0.5763	1.0000
low_confidence	F1	0.9116	0.9112	0.9096	0.9055	0.9013	0.8660
	HCR	0.6000	0.8000	1.0000	1.0000	0.9935	0.9326
	RR	0.0000	0.0000	0.0065	0.0769	0.2048	1.0000
manual_linear	F1	0.9106	0.9096	0.9077	0.9032	0.8989	0.8660
	HCR	1.0000	1.0000	0.9913	0.9913	0.9812	0.9326
	RR	0.0129	0.0614	0.1644	0.2820	0.4614	1.0000
logistic	F1	0.9076	0.9006	0.8942	0.8856	0.8782	0.8660
	HCR	0.6813	0.8059	0.8697	0.8977	0.9156	0.9326
	RR	0.4649	0.5103	0.6686	0.8397	0.9347	1.0000
lightgbm	F1	0.9094	0.9050	0.8966	0.8838	0.8744	0.8660
	HCR	0.6597	0.7708	0.8452	0.8960	0.9158	0.9326
	RR	0.6236	0.7455	0.8562	0.9230	0.9700	1.0000
review_acceptance	F1	0.9117	0.9116	0.9115	0.9115	0.9115	0.9115
	HCR	0.4000	0.4000	0.4000	0.4000	0.4000	0.4000
	RR	0.4649	0.5103	0.6686	0.8397	0.9347	1.0000

TABLE XIV
无额外扰动时直接 XOR 与容差 XOR 比较

设置	漏检恢复率	XOR 占比
ECC+ 直接 XOR	23/343=6.71%	0.02892
ECC+ 容差 XOR	81/343=23.62%	0.01441

TABLE XV
RQ4 检测器替换结果

设置	F1	mAP@0.5	HCR
RT-DETR-R18VD 基线	0.6416	0.6483	不适用
RT-DETR-R18VD+ 完整流程	0.6416	0.6483	0.0000

议仍会造成 F1 下降；只有接受门时，安全性较高，却无法降低大模型调用成本。

F. RQ4：鲁棒性与模型替换

RQ4 在 fold_0 的 325 张测试图像上进行。几何扰动施加于正常模板，光度扰动施加于待检图；每个条件重新计算配准、光度归一、外观残差、骨架差异和差异候选。几何实验组合无二次配准或 ECC 配准、直接 XOR 或容差 XOR 以及是否使用质量门，共产生 8775 条图像与扰动条件评价记录。fold_0 共有 343 个基础漏检，漏检恢复率以完整测试折为分母，定义为差异候选与未覆盖真值框达到 IoU 不低于 0.3 的比例。最终 F1 和 HCR 使用 fold_0 的 800 个真实 A2 结论冻结回放，只重算扰动影响的证据与门控特征。该协议隔离了配准证据退化，但不等价于在每种扰动下重新调用大模型。

*1) 容差 XOR 与配准质量：*无额外扰动时，ECC 加直接 XOR 恢复 23 个漏检，恢复率为 $23/343 = 6.71\%$；改用容差 XOR 后恢复 81 个，达到 $81/343 = 23.62\%$，提升约 3.5 倍。与此同时，XOR 伪差异像素占比从 0.02892 降至 0.01441，降低约 50%。容差操作允许骨架在小邻域内匹配，能够压制由 JPEG 边缘和亚像素错位产生的双边轮廓，同时保留真实线路断开或多余连接。表 XIV说明恢复率提高并非以更多伪差异面积为代价。

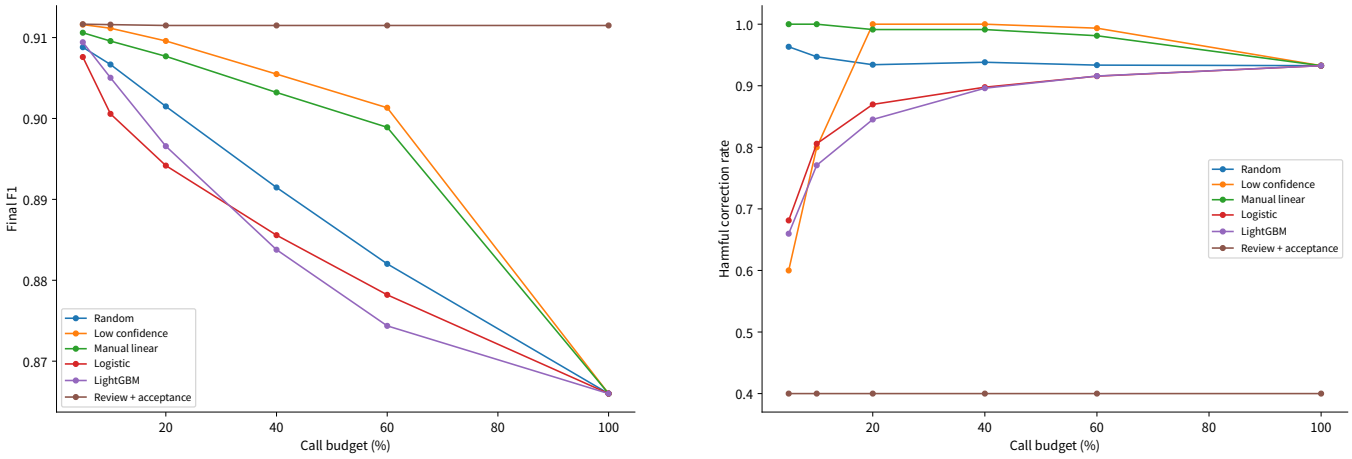
在同方向正平移序列中，q_{reg} 均值随扰动增大而下降：无扰动为 0.8599，平移 2 像素为 0.8410，平移 8 像素为 0.7992；对应 $q_{\mathrm{reg}} < 0.5$ 的比例为 4.00%、4.62% 和 4.92%。这条受控序列说明质量分能够响应逐渐增强的错位，而不是近似常数。平移 8 像素时，完整设置的 F1 为 0.8796，HCR 为 1.0000。这里每个相关强扰动条件只有 1 个被接受动作且该动作有害，因此 HCR 为 1 不表示大量候选都被破坏，却证明少量放行动作仍可能失败。

完整报告同时给出质量门的负面边界。全部几何条件中，冻结阈值 0.5 的质量门没有拦截任何有害动作，因为这些候选的 q_{reg} 没有低于阈值。q_{reg} 同时惩罚估计变换幅度，ECC 修正真实初始错位后，其分数有时反而低于以恒等变换计算的代理分数。因此，本实验只支持 q_{reg} 对选定平移强度序列的下降趋势，不支持它在所有几何扰动间严格单调，也不支持当前阈值已经形成可靠的风险保证。这个限制与容差 XOR 的明确收益需要分开陈述。

光度扰动包括亮度 ±10、±20，对比度 0.8 和 1.2，两档噪声以及两档模糊。完整设置在这些条件下的最终 F1 均为 0.8803，HCR 均为 0。DeepPCB 像素主要集中在 0 和 255 附近，较小光度变化的区分度有限；稳定结果只能说明冻结回放协议下没有触发额外有害修改，不能推广为对任意成像变化鲁棒。

*2) 检测器与门控模型替换：*检测器替换采用官方 PekingU RT-DETR-R18VD，在 fold_0 训练后对全部测试图像预测，并对 200 个比例分层候选调用 A2 验证器。表 XV显示，RT-DETR-R18VD 基线 F1 为 0.6416，mAP@0.5 为 0.6483，明显低于 YOLOv8s 五折工作点。完整流程实际调用 12 次，但没有接受任何修改，最终 F1 仍为 0.6416，HCR 为 0。至少在这一检测器替换对照中，双门控的安全性不依赖 YOLOv8s，可以在较弱检测器上保持不退化；由于没有执行动作，不能据此宣称流程能改善不同架构的检测性能。

门控模型替换也限制在 fold_0 的 200 个分层候选上。Logistic 在验证阈值 0.208300 下调用 0 次，LightGBM 在阈值 0.145905 下调用 3 次，两者最终 F1 均为 0.8803，HCR 均为 0。该小样本对照说明安全规则没有因门控分类器变化而立即失效，但调用数过少，不足以比较两种模型的纠错能力。



(a) F1 与调用率　　(b) HCR 与调用率

Fig. 6. 不同门控策略的性能、风险与调用预算关系

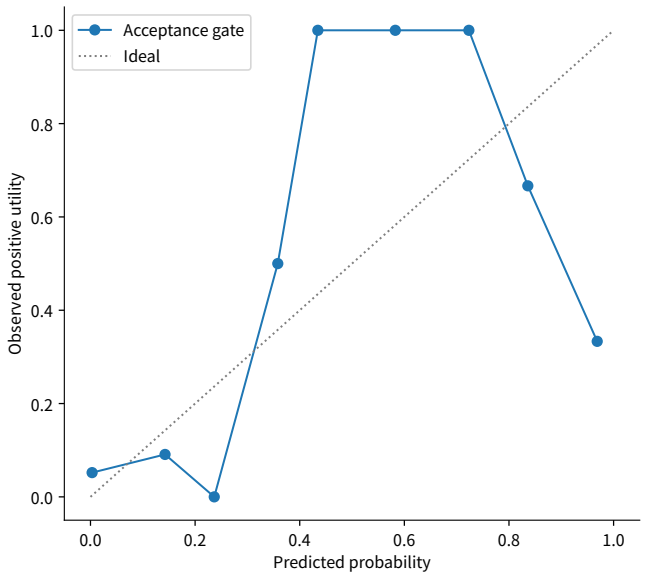


Fig. 7. 接受门的可靠性分析

第二个多模态大模型后端未完成对照，HRIPCB 也未纳入实验。因而 RQ4 最稳固的发现是容差 XOR 在 DeepPCB fold_0 上同时提高漏检候选恢复率并减少伪差异，以及双门控在 RT-DETR-R18VD 对照中没有接受有害修改。关于跨检测器增益、跨数据集泛化和跨大模型一致性的主张均超出当前证据范围。

G. 讨论与局限

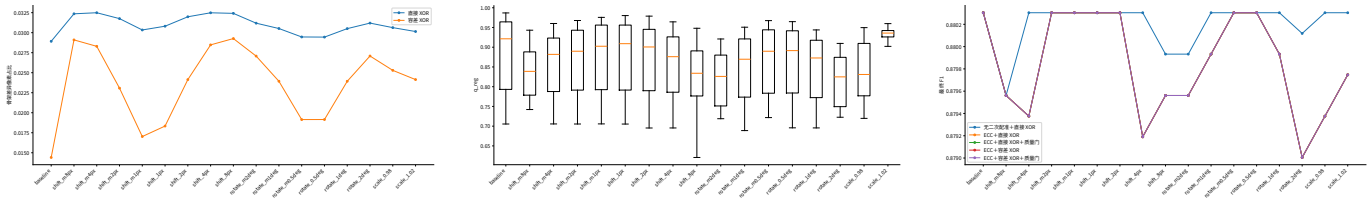
四个研究问题共同描绘出一个明确的能力边界。正常模板能显著提高大模型的候选存在性判断，完整外观与拓扑证据却没有稳定增益；双来源候选保留了较高的 Oracle-C 上界，真实大模型输出的 Oracle-A 增益却很小；复检门能在低预算下集中覆盖错误候选，接受门能阻止调用预算扩大造成的性能下降；端到端 Full 仍没有超过基础工作点。系统当前的主要价值是风险受控地暴露多模态大模型在工业细粒度复核中的不足，而不是已经实现稳定的检测指标提升。以下四项局限限定了结论适用范围。

第一，接受门的训练分布与部署时提议分布不完全匹配。训练阶段的 remove、relabel 和 add 提议由冻结的确定性证据代理生成，正效用标签由折外检测和真值计算；端到端部署时的提议则来自真实大模型。代理提议与大模型提议在类别频率、错误模式和分数分布上可能不同，造成接受概率失配。该问题直接影响 HCR、动作召回和阈值可靠性，也可能解释接受门过度保守、Oracle-A 仍高于 Full 的部分差距。它不影响 YOLOv8s 基础检测指标、RQ1 的证据输入比较和 Oracle-C 候选覆盖结论。后续应使用已经积累的约 7000 次真实调用重训接受门，并在独立模板组上重新校准阈值。

第二，实验只有一个真实多模态大模型后端。RQ1 的证据偏好、自由文本解析失败、标签可见对照以及 RQ2 中 Oracle-A 上限均可能依赖 `gpt-5.6-sol` 的视觉能力和指令遵循特性。当前结果可以支持“该后端在本协议下判断质量不足”，不能推广为所有视觉语言模型都无法完成 PCB 细粒度复核。检测器替换并不能弥补这一缺口，因为验证器保持不变。该局限影响所有涉及大模型正确率和提示行为的结论，但不影响数据泄漏判断、基础错误分解、容差 XOR 的确定性候选结果和调用成本的实测口径。

第三，RQ2 采用分层抽样候选评价。五折固定候选总数为 51222，每折只调用 800 个，覆盖比例为 5.5% 至 12.5%，未抽中的候选保持 B1 输出。这样能够在调用预算内公平比较 B7、B8 和 Full，也能对抽样区域中的错误转移作精确计数，但端到端净收益会被大量未修改候选稀释，稀有正确动作也可能没有进入样本。Full 相对 B1 的 bootstrap 区间只描述本抽样与冻结响应协议，不等于对 51222 个候选全部调用后的区间。Oracle-C 使用完整固定候选集，仍可用于判断候选覆盖潜力；Oracle-A、FPCR、MDRR、MCCA 和错误转移矩阵则受抽样范围约束。

第四，fold_0 测试集只包含 group20085 一个模板组。该折有 325 对图像，样本量最大但板型多样性最低，RQ4 又主要在该折执行，因此其扰动结果可能混合单一模板的结构特征。五折总体检测与 RQ2 主表仍覆盖全部 11 个模板组，fold_0 的单组性质主要限制 RQ4 配准趋势、RT-



(a) XOR 表示比较　(b) 配准质量分布　(c) 配准扰动性能

Fig. 8. 配准扰动、质量分与容差 XOR 的鲁棒性结果

DETR 替换和门控替换的外推范围。后续应至少在其余四折重复关键扰动，并按模板组汇总 q_{reg} 和漏检恢复率，确认容差 XOR 收益不是 group20085 特有现象。

在这些边界内，可以形成三项不夸大的实验判断。其一，官方划分的模板泄漏足以改变实验设计，按模板组隔离是主结论成立的前提。其二，正常模板、学习式复检排序和动作接受门分别在证据、成本和安全三个层面得到实证支持，但完整证据卡与去锚定协议没有显示稳定优势。其三，Oracle-C 与 Oracle-A 之间的显著差距把当前瓶颈定位到大模型判断质量，Full 与 B1 统计无差别以及 2 次误删 TP 必须作为主要结果保留，而不能用安全门控的正面表现加以掩盖。

VII. 总结与展望

A. 工作总结

本文研究了正常模板可用条件下的 PCB 检测结果复核问题，构建了由候选生成、多模态大模型判断、复检门和接受门组成的后置系统。实验为三项贡献提供了不同层面的支撑。

第一，本文将基础检测候选与参考差异候选合并，使复核范围不受基础检测器输出限制。阶段 A 调参后，差异候选在 IoU 0.3 下的漏检恢复率达到 0.625；候选 Oracle 的 F1 为 0.9555，相对基础方法仍有约 0.044 的可用空间。这说明双来源候选能够覆盖一部分基础检测器未提出的缺陷假设，但候选覆盖并不等同于端到端纠错收益。

第二，本文把配准质量、检测不确定性和候选来源用于分级复检。在 5% 调用预算下，Logistic 复检门覆盖 46.49% 的可纠错错误，随机选择仅覆盖 3.15%，前者的错误定位效率约为后者的 14.8 倍。扰动实验中，配准质量分数随平移幅度增大而单调下降；严重错位会使有害修正率升至 1.0，验证了配准质量门对系统降级的必要性。

第三，本文用学习式接受门和硬安全规则约束大模型动作。完整系统的正确检测保留率达到 0.9998，734 个正确检测中仅误删 2 个。无门控全量复检的有害修正率为 0.9326，说明大模型建议不能被直接执行；加入接受门后，不同调用预算下的 F1 均保持在基础检测器附近。该结果支持双门控的安全性贡献。

显式外观差异图与拓扑图没有形成预期贡献。候选级消融中，仅加入正常模板的配置取得稳定增益，堆叠全部证据的配置未获得显著提升；后续 450 次专门对照中的证据变体也全部低于仅用正常模板的配置。最终系统因此移除了显式差异视觉输入，只保留拓扑统计作为门控特征。去锚定设计同样没有得到充分支持，提供检测标签的对照反而更好。本文将这两项结果作为方法边界报告，而不继续使用原创新表述。

B. 结论与能力边界

双门控达成了预设的安全目标，却没有带来可观的端到端净收益。五折实验中，完整系统 F1 为 0.9117 ± 0.0343，基础方法为 0.9118 ± 0.0344；二者的配对 bootstrap 差值为 -0.000064，95% 置信区间为 $[-0.000273, +0.000094]$。完整系统 mAP@0.5 为 0.8810，基础方法为 0.8813。当前证据不支持“复核系统提升整体检测精度”的结论。

Oracle 分析进一步定位了瓶颈。候选 Oracle 的 F1 达到 0.9555，说明候选集合仍包含可利用的纠错空间；即使假设接受门完美选择当前大模型提出的动作，Oracle-A 的 F1 也只有 0.9143，仅比基础方法高 0.0025。由此可见，当前多模态大模型对工业细粒度缺陷的判断和动作提议质量是主要限制，而不是候选覆盖或双门控结构。本文能够确认的结论是：复检门显著提高有限预算下的错误候选命中效率，接受门把有害修改限制在很低水平，系统安全性成立，但净收益接近零。

C. 未来工作

后续研究首先应解决接受门的训练分布不匹配。现有接受门使用确定性证据代理产生的动作训练，而实验已经积累约 7000 次真实大模型调用及其缓存输出。可据此重建动作级训练集，按模板组隔离训练与测试，重新学习“何时接受真实模型建议”，并继续以正确检测保留率和有害修正率作为硬约束。

第二，需要引入至少一个独立的多模态大模型后端，在相同候选、证据卡、提示和预算下进行配对比较。跨模型一致的失败可归因于任务或证据设计，模型间差异则可用于分析领域能力、校准和动作偏好，避免把单一后端的结论泛化为所有多模态大模型的能力边界。

第三，应在 HRIPCB 上开展跨模板验证。实验划分需要按模板分组，避免同一模板跨训练集与测试集造成泄漏，并分别报告配准成功率、差异候选召回、门控覆盖率与最终检测指标。该实验可以检验双门控安全性是否能从当前 DeepPCB 设置迁移到旋转变化和更多模板条件。

第四，若目标是获得实质性的端到端增益，应把研究重点转向工业细粒度缺陷的领域适配。可使用候选级正常与缺陷图对、缺陷类别知识和真实纠错动作进行监督微调或偏好优化，并以第二模型或外部视觉专家提供对照反馈。领域适配后的模型仍需经过独立接受门，避免能力提升与系统安全约束相互替代。

References

[1] Y.-S. Deng, A.-C. Luo, and M.-J. Dai, “Building an automatic defect verification system using deep neural network for PCB defect classification,” in *2018 4th International Conference on Frontiers of Signal Processing (ICFSP)*, 2018, pp. 145–149.

[2] X. Chen, Y. Wu, X. He, and W. Ming, "A comprehensive review of deep learning-based PCB defect detection," *IEEE Access*, vol. 11, pp. 139 017–139 038, 2023.

[3] S. Tang, F. He, X. Huang, and J. Yang, "Online PCB defect detector on a new PCB defect dataset," 2019. [Online]. Available: https://arxiv.org/abs/1902.06197

[4] Y. Fridman, M. Rusanovsky, and G. Oren, "ChangeChip: A reference-based unsupervised change detection for PCB defect detection," in *2021 IEEE Physical Assurance and Inspection of Electronics (PAINE)*, 2021.

[5] X. Jiang, J. Li, H. Deng, Y. Liu, B.-B. Gao, Y. Zhou, J. Li, C. Wang, and F. Zheng, "MMAD: A comprehensive benchmark for multimodal large language models in industrial anomaly detection," in *International Conference on Learning Representations*, 2025.

[6] J. Xu, S.-Y. Lo, B. Safaei, V. M. Patel, and I. Dwivedi, "Towards zero-shot anomaly detection and reasoning with multimodal large language models," in *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025.

[7] M. Andrade, J. Cha, B. Ho, V. Srihari, K. Yadav, and Z. Kira, "Let's think in two steps: Mitigating agreement bias in MLLMs with self-grounded verification," in *International Conference on Learning Representations*, 2026.

[8] W. Huang and P. Wei, "A PCB dataset for defects detection and classification," 2019. [Online]. Available: https://arxiv.org/abs/1901.08204

[9] S. Lv, B. Ouyang, Z. Deng, T. Liang, S. Jiang, K. Zhang, J. Chen, and Z. Li, "A dataset for deep learning based detection of printed circuit board surface defect," *Scientific Data*, vol. 11, p. 811, 2024.

[10] H. Yan, X. Yu, B. Ma, H. Zhang, Y. Liu, G. Huang, S. Xie, J. Li *et al.*, "Industrial printed circuit board surface defect dataset for object detection," *Scientific Data*, 2026.

[11] Y. Zou, J. Jeong, L. Pemula, D. Zhang, and O. Dabeer, "SPot-the-Difference self-supervised pre-training for anomaly detection and segmentation," in *European Conference on Computer Vision*, 2022, pp. 392–408.

[12] Y. Miao, Z. Liu, X. Wu, and J. Gao, "Cost-sensitive siamese network for PCB defect classification," *Computational Intelligence and Neuroscience*, p. 7550670, 2021.

[13] V. Edula, N. Badwe, and P. Bagade, "RefDiffNet: Learning to expose subtle PCB defects before detection," 2026. [Online]. Available: https://arxiv.org/abs/2606.00852

[14] Z. Gu, B. Zhu, G. Zhu, Y. Chen, M. Tang, and J. Wang, "AnomalyGPT: Detecting industrial anomalies using large vision-language models," *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 38, no. 3, pp. 1932–1940, 2024.

[15] H. Deng, H. Luo, W. Zhai, Y. Cao, and Y. Kang, "VMAD: Visual-enhanced multimodal large language model for zero-shot anomaly detection," 2024. [Online]. Available: https://arxiv.org/abs/2409.20146

[16] W. Guan, J. Lan, J. Cao, H. Tan, H. Zhu, and W. Wang, "EMIT: Enhancing MLLMs for industrial anomaly detection via difficulty-aware GRPO," 2025. [Online]. Available: https://arxiv.org/abs/2507.21619

[17] F. Sun, X. Jiang, J. Wu, H. Zhang, F. Zheng, and J. Yang, "UniPCB: A unified vision-language benchmark for open-ended PCB quality inspection," 2026. [Online]. Available: https://arxiv.org/abs/2601.19222

[18] D. Wang, X. Tao, Z. Qu, H. Luo, X. Gong, F. Shen, Z. Zhang, and G. Ding, "DifferAD-R1: A difference-guided industrial anomaly localization with multimodal large language models," 2026. [Online]. Available: https://arxiv.org/abs/2606.16601

[19] Y. Geifman and R. El-Yaniv, "SelectiveNet: A deep neural network with an integrated reject option," in *International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, vol. 97, 2019, pp. 2151–2159. [Online]. Available: https://proceedings.mlr.press/v97/geifman19a.html

[20] C. Guo, G. Pleiss, Y. Sun, and K. Q. Weinberger, "On calibration of modern neural networks," in *International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, vol. 70, 2017, pp. 1321–1330. [Online]. Available: https://proceedings.mlr.press/v70/guo17a.html

[21] H. Mozannar and D. Sontag, "Consistent estimators for learning to defer to an expert," in *International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, vol. 119, 2020, pp. 7076–7087. [Online]. Available: https://proceedings.mlr.press/v119/mozannar20b.html

[22] A. N. Angelopoulos, S. Bates, A. Fisch, L. Lei, and T. Schuster, "Conformal risk control," in *International Conference on Learning Representations*, 2024. [Online]. Available: https://proceedings.iclr.cc/paper_files/paper/2024/hash/f3549ef9b5ff520a7e41ff3cc306ab2b-Abstract-Conference.html

[23] R. Kamoi, Y. Zhang, N. Zhang, J. Han, and R. Zhang, "When can LLMs actually correct their own mistakes? a critical survey of self-correction of LLMs," 2024. [Online]. Available: https://arxiv.org/abs/2406.01297

[24] M. Imran and Y. Lee, "Predicting when to trust vision-language models for spatial reasoning," 2026. [Online]. Available: https://arxiv.org/abs/2601.11644